



**UNIVERSIDAD
DE GRANADA**

TRABAJO FIN DE GRADO

GRADO EN INGENIERÍA INFORMÁTICA

Aplicación Del Procesamiento Del Lenguaje Natural Cuántico

Autor

Daniel Terés Martínez

Directores

Manuel Pegalajar Cuéllar

Serafín Moral García



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

—
13 de mayo de 2026

Aplicación Del Procesamiento Del Lenguaje Natural Cuántico

Daniel Terés Martínez

Palabras clave: palabra_clave1, palabra_clave2, palabra_clave3,

Resumen

Poner aquí el resumen.

Yo, **Daniel Terés Martínez**, alumno de la titulación Grado en Ingeniería Informática de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 41542052G, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Daniel Terés Martínez

Granada 13 de mayo de 2026.

D. **Manuel Pegalajar Cuéllar**, Profesor del Área de XXXX del Departamento Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

D. **Serafín Moral García**, Profesor del Área de XXXX del Departamento Departamento de Ciencias de la Computación e Inteligencia Artificial de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado ***Aplicación Del Procesamiento Del Lenguaje Natural Cuántico***, ha sido realizado bajo su supervisión por **Daniel Terés Martínez**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada 13 de mayo de 2026.

Los directores:

Manuel Pegalajar Cuéllar Serafín Moral García

Agradecimientos

Poner aquí agradecimientos...

Índice general

1. Introducción	1
1.1. Motivación	3
1.2. Objetivos	4
1.3. Estructura del documento	4
2. Conceptos previos	7
2.1. Procesamiento Lenguaje Natural	7
2.1.1. Introducción al Procesamiento del Lenguaje Natural .	7
2.1.2. Fases del PLN	7
2.2. Computación cuántica	11
2.2.1. Números complejos	11
2.2.2. Qubits	17
2.2.3. Procesamiento del Lenguaje Natural Cuántico	23
3. Estado del arte	31
3.1. Representación Vectorial de Palabras (Word Embeddings) . .	31
3.1.1. Introducción al concepto de <i>Embedding</i>	31
3.1.2. Mecanismos geométricos de los embeddings	34
3.1.3. Paralelismo entre Espacio Semántico y Espacio de Hilbert	38
3.2. Implementación Clásica: Algoritmo Word2Vec	40
3.2.1. Arquitectura del modelo	40
3.2.2. Función de optimización	45
3.3. Implementación Cuántica: Algoritmo QWord2Vec	48
3.3.1. Adaptación del algoritmo al entorno cuántico	48
3.3.2. Diseño del Circuito Cuántico Parametrizado	48
3.3.3. Definición de la función de evaluación y pérdida usadas	51
3.3.4. Estrategia de optimización	53
4. Experimentación y Análisis de Resultados	57
4.1. Metodología experimental	57
4.1.1. Dataset y preprocesamiento	58
4.1.2. Entorno de ejecución y herramientas	59

4.1.3.	Configuración de hiperparámetros	60
4.1.4.	Hiperparámetros de Word2Vec	60
4.1.5.	Hiperparámetros de QWord2Vec	62
4.2.	Entrenamiento	64
4.2.1.	Word2Vec	64
4.2.2.	QWord2Vec	67
4.3.	Evaluación de los embeddings	70
4.3.1.	Visualización de los <i>embeddings</i>	71
4.3.2.	Similitud coseno	72
4.3.3.	Correlación de Pearson y métricas finales	74
4.3.4.	Discusión	74
4.4.	Experimentación con corpus ampliado	76
4.4.1.	Ampliación del corpus	76
4.4.2.	Reajuste de hiperparámetros	76
4.4.3.	Resultados de Word2Vec	78
4.4.4.	Resultados de QWord2Vec	80
4.4.5.	Comparación entre fases	81
4.5.	Análisis de tiempos de ejecución	83
5.	Conclusiones y trabajo futuro	85
5.1.	Conclusiones	85
5.2.	Trabajo a futuro	87
	Bibliografía	91
	Glosario	97

Capítulo 1

Introducción

La computación cuántica se ha consolidado como un campo emergente de la informática y la ingeniería que aprovecha los principios fundamentales de la mecánica cuántica (como la superposición, el entrelazamiento y la interferencia) para resolver problemas de una complejidad inalcanzable para los ordenadores clásicos más potentes [41]. A diferencia de la computación clásica que se basa en bits que representan estados binarios, esta disciplina hace uso de qubits, permitiendo explorar espacios computacionales multidimensionales. El potencial teórico de estas máquinas fue evidenciado en 1994, cuando el matemático Peter Shor publicó su famoso algoritmo de factorización de enteros, demostrando cómo una máquina cuántica podría romper los sistemas criptográficos más avanzados y sentando las bases de su aplicabilidad práctica [44].

En la actualidad, las principales empresas tecnológicas continúan invirtiendo fuertemente en este ecosistema, proyectando que la computación cuántica impulsará una industria sin precedentes en la próxima década [30]. Esta tecnología destaca por proporcionar dos ventajas fundamentales: la capacidad de modelar el comportamiento de sistemas físicos complejos de forma nativa (el universo opera bajo reglas cuánticas) y la habilidad para estructurar y descubrir patrones ocultos en grandes volúmenes de información matemática. Gracias a ello, los dominios de aplicación se han expandido drásticamente, destacando su uso actual en la química molecular para el descubrimiento de nuevos fármacos, la optimización de infraestructuras energéticas sostenibles, el modelado avanzado en mercados financieros y, por supuesto, en la seguridad de la información.

Dentro de este contexto de rápida evolución tecnológica, el campo del Quantum Machine Learning (QML) está creciendo de forma acelerada, integrando la potencia de los algoritmos de inteligencia artificial con el procesamiento cuántico. Su desarrollo busca abordar de forma más eficiente problemas de clasificación, modelos generativos y regresión, dominios que tradicionalmente domina el Machine Learning (ML) clásico [7, 6, 33]. Los

expertos coinciden en que este enfoque no solo permitirá ejecutar cálculos muy complejos para los sistemas convencionales, sino que existe evidencia teórica y empírica de una clara ventaja cuántica en las propias tareas de aprendizaje. Estudios recientes han demostrado que, bajo ciertas condiciones de datos, arquitecturas como los circuitos cuánticos parametrizados o los modelos de *kernels* cuánticos proyectados logran mejoras sustanciales tanto en la velocidad de entrenamiento como en la capacidad de generalización frente a las redes neuronales clásicas óptimas [1, 21, 8]. Esta superioridad teórica radica precisamente en la capacidad de los modelos para mapear características complejas en un espacio de Hilbert cuyo tamaño crece exponencialmente con el número de qubits.

De forma paralela a los avances cuánticos, el Procesamiento del Lenguaje Natural (PLN) ha experimentado su propia revolución técnica, de una forma muy abrubta durante la última década. El pilar fundamental de esta transformación ha sido el desarrollo de los *word embeddings*, representaciones vectoriales que permiten codificar de forma eficiente las propiedades semánticas y sintácticas de las palabras dentro de un espacio matemático continuo. La consolidación práctica de esta técnica llegó con la publicación del algoritmo Word2Vec [31] por parte de investigadores de Google en 2013, un modelo que demostró tal eficacia en la captura del contexto lingüístico que transformó radicalmente la efectividad de los sistemas de recuperación de información y motores de búsqueda (por ejemplo, Google lo utiliza a día de hoy para su motor de búsqueda), manteniéndose así hasta la fecha como una referencia en esta disciplina. Ha sido precisamente sobre la madurez de estos cimientos del PLN que el ámbito más amplio de la Inteligencia Artificial (IA) ha logrado dar su salto más impactante en estos últimos años con la irrupción de los Large Language Models (LLMs). Modelos tan conocidos a día de hoy como ChatGPT, Gemini o Claude, que en su nivel de procesamiento más básico siguen dependiendo de la conversión matemática de las palabras, es decir, de los *word embeddings*, han demostrado una capacidad sin precedentes para comprender, procesar y generar lenguaje humano natural.

La intersección entre ambas disciplinas ha dado lugar al Procesamiento del Lenguaje Natural Cuántico (PLNC), una línea de investigación que busca aprovechar los fenómenos de la cuántica, como la superposición y el entrelazamiento, para representar y procesar el lenguaje de manera más eficiente. Aunque se han propuesto modelos de inspiración cuántica para recuperación de información [59, 60] y para embeddings de palabras [25], hasta hace muy poco (menos de 1 año), no existía ningún circuito cuántico diseñado específicamente para aprender representaciones de palabras, es decir, un equivalente cuántico de Word2Vec.

El reciente trabajo publicado por Ohno [33] marca un hito en la disciplina al proponer *QWord2Vec*, la primera adaptación formal de la arquitectura clásica de Word2Vec al entorno computacional cuántico. Este modelo

se articula en torno a un circuito cuántico parametrizado que, guiado por el optimizador Simultaneous Perturbation Stochastic Approximation (SP-SA) y una función de pérdida combinada (entropía cruzada y coeficiente de correlación de Pearson), logra aprender *embeddings* cuánticos de palabras utilizando corpus de texto de tamaño reducido, dadas las limitaciones impuestas por los simuladores cuánticos actuales. Es precisamente este modelo emergente el que ha sido basado el presente Trabajo de Fin de Grado.

1.1. Motivación

La motivación principal de este trabajo es explorar si un modelo cuántico es capaz de aprender relaciones semánticas entre palabras con una calidad comparable a la del modelo clásico Word2Vec. Dicho modelo, que constituye el punto de referencia de este trabajo, lleva más de una década consolidado como uno de los estándares fundamentales del PLN. La pregunta central que se pretende responder es, por tanto: ¿puede el espacio de Hilbert, con su capacidad para representar estados en superposición y aprovechar el entrelazamiento cuántico, servir como espacio latente para los *embeddings* de palabras con resultados equiparables o superiores a los del espacio euclídeo clásico?

Más allá de esta pregunta, el trabajo ofrece también la oportunidad de estudiar en profundidad la frontera actual entre el PLN y la computación cuántica, dos de los campos más dinámicos de la ciencia computacional contemporánea. Para ello, se recorren tanto los fundamentos matemáticos imprescindibles (notación de Dirac, qubits y circuitos cuánticos parametrizados) como los fundamentos del PLN clásico (representaciones vectoriales de palabras y Word2Vec), hasta alcanzar su convergencia en el modelo QWord2Vec.

En este trabajo se adopta una perspectiva metodológica distinta a la empleada en la investigación de referencia [33]. Mientras que el objetivo fundamental de dicho estudio original consistía en entrenar ambos modelos bajo condiciones lo más idénticas posible para evaluar en qué medida la versión cuántica lograba reproducir las representaciones vectoriales de su contraparte clásica, en nuestro enfoque se ha optado por entrenar cada arquitectura aplicando las mejores técnicas y optimizaciones disponibles dentro de su propio ecosistema. Con esta aproximación, se persigue determinar empíricamente qué paradigma es capaz de ofrecer los resultados más competitivos bajo las condiciones tecnológicas que rigen el estado del arte actual.

Esta aproximación no cuestiona la dirección de la investigación en PLNC, sino que la complementa planteando una pregunta diferente ¿cuán madura se encuentra hoy la computación cuántica para competir con una técnica clásica tan consolidada como Word2Vec en el campo de PLN? Dado que QWord2Vec

fue propuesto hace menos de un año, los resultados de este trabajo deben interpretarse como un diagnóstico del estado actual del campo, y no como una valoración definitiva de su potencial futuro.

1.2. Objetivos

El objetivo principal de este trabajo es implementar, evaluar y proponer mejoras algorítmicas sobre el modelo cuántico de representación de palabras QWord2Vec, analizando su viabilidad técnica y rendimiento empírico frente al estándar clásico Word2Vec. Para alcanzar este propósito general, la investigación se ha descompuesto en los siguientes objetivos específicos:

1. Estudiar y comprender los fundamentos de la computación cuántica necesarios para diseñar e implementar circuitos cuánticos parametrizados.
2. Estudiar el algoritmo Word2Vec clásico y su variante Skip-gram, analizando su arquitectura y proceso de entrenamiento.
3. Comprender la propuesta de QWord2Vec [33]: su circuito cuántico parametrizado, la función de pérdida empleada y la estrategia de optimización que usó.
4. Implementar ambos modelos (Word2Vec y QWord2Vec) en Python, utilizando las librerías Gensim y Qiskit respectivamente, entrenando cada uno con las mejores técnicas disponibles en su paradigma.
5. Evaluar la calidad de los *embeddings* generados por QWord2Vec y compararlos con los producidos por Word2Vec mediante el coeficiente de correlación de Pearson.
6. Proponer y evaluar modificaciones sobre la función de optimización y la inicialización de parámetros del modelo QWord2Vec, analizando su impacto en el entrenamiento y en la calidad de los *embeddings* obtenidos.

1.3. Estructura del documento

El resto del documento se organiza de la siguiente manera. En primer lugar, se presentan los fundamentos matemáticos imprescindibles: el **Capítulo 2.2.1** introduce los números complejos, así como describe la notación de Dirac, ambos necesarios para trabajar con estados cuánticos. El **Capítulo 2.2.2** describe qué es un qubit, cómo se representa y qué operaciones pueden realizarse sobre él.

A continuación, los capítulos de PLN: el **Capítulo 2.1** introduce el procesamiento del lenguaje natural clásico y sus fases principales; el **Capítulo 2.2.3** presenta el procesamiento del lenguaje natural cuántico y su motivación; el **Capítulo 3.1** describe los word embeddings y el espacio latente; y el **Capítulo 3.2** explica en detalle el algoritmo Word2Vec y su variante Skip-gram.

El **Capítulo 3.3** es el núcleo técnico del trabajo, describe la arquitectura del circuito cuántico de QWord2Vec, la función de pérdida empleada y el optimizador Quantum Natural Simultaneous Perturbation Stochastic Approximation (QN-SPSA). Sobre esta base, el **Capítulo 4** recoge el proceso experimental, los resultados obtenidos y el análisis comparativo entre los dos modelos. Finalmente, el **Capítulo 5** resume los resultados obtenidos, valora el cumplimiento de los objetivos planteados y propone las líneas de trabajo futuro orientadas a extender QWord2Vec hacia corpus de mayor escala y aplicaciones reales.

Capítulo 2

Conceptos previos

2.1. Procesamiento Lenguaje Natural

2.1.1. Introducción al Procesamiento del Lenguaje Natural

El Procesamiento del Lenguaje Natural (PLN) es la rama de la IA encargada de la interacción entre computadoras y el lenguaje humano. Este campo integra la lingüística computacional, basada en el modelado de reglas del lenguaje, con modelos estadísticos y algoritmos de aprendizaje profundo (Deep Learning (DL)) y aprendizaje automático (ML) [49].

El PLN forma parte a día de hoy de muchos motores de búsqueda, chatbots para atención al cliente (ya sea por escrito o por voz), y asistentes digitales como Alexa de Amazon o Siri de Apple.

El campo de la computación lingüística incluye tradicionalmente diversas fases para el análisis. Para el análisis de las palabras existen dos enfoques principales:

- **Análisis de dependencias:** Examina las relaciones gramaticales binarias entre las palabras, identificando, por ejemplo, qué palabra modifica a cuál o cuál es el sujeto y el verbo principal.
- **Análisis de constituyentes:** Construye un árbol sintáctico que representa la estructura gramatical anidada de una oración, descomponiéndola en sintagmas o frases ordenadas jerárquicamente.

2.1.2. Fases del PLN

Las fases para realizar el PLN se pueden observar en la Figura 2.1:

A continuación, basándose en la estructura descrita en [15], se detalla en qué consiste cada una de estas fases:




Figura 2.1: Esquema de las fases del PLN. Extraído de [15].

Preprocesamiento y Tokenización

Esta fase constituye el nivel inicial del procesamiento lingüístico computacional. Su propósito fundamental es transformar el texto crudo en una secuencia estructurada de unidades discretas y manejables. Para lograrlo, se integran diversas tareas de análisis léxico y morfológico que preparan la información para las etapas posteriores.

1. **Preprocesamiento:** Esta fase inicial comprende un conjunto de operaciones destinadas a homogeneizar el texto. Entre las principales sub-tareas se encuentran la limpieza del contenido, la normalización (como la conversión a minúsculas) y la eliminación de caracteres especiales. Adicionalmente, suele llevarse a cabo la supresión de las *stopwords*, que son palabras de muy alta frecuencia pero que carecen de una gran carga semántica (tales como “el”, “de”, “y”). Como parte de este preprocesamiento, también se aplican técnicas de análisis morfológico para estandarizar el vocabulario:
 - *Lematización:* Consiste en convertir las palabras a su forma base o lema canónico (por ejemplo, el verbo “soy” se transforma en “ser”).
 - *Stemming:* Se basa en reducir las palabras a su raíz léxica, eliminando sufijos y prefijos (por ejemplo, “niñero” se reduce a “niño”).
2. **Tokenización:** Representa el proceso crítico mediante el cual se segmenta el flujo de texto en unidades atómicas significativas, denominadas *tokens*.

A modo de ejemplo, la oración *Me gusta programar* se dividiría en la siguiente lista de tokens: [‘Me’, ‘gusta’, ‘programar’].

La granularidad de los tokens depende del modelo empleado. Pueden corresponder a palabras completas, subpalabras (una técnica común en los modelos de tipo Generative Pre-trained Transformer (GPT)) o incluso a caracteres individuales. Una vez completada la tokenización, a cada token se le asigna un índice numérico único dentro de un vocabulario, un paso indispensable para la posterior generación de representaciones vectoriales o *Embeddings* (concepto que se desarrollará en detalle en el Capítulo 3.1).

3. **Etiquetado gramatical (Part-of-Speech (POS) Tagging):** En esta etapa se asigna a cada token su correspondiente categoría morfológica (como sustantivo, verbo, adjetivo, entre otras), tomando en consideración tanto su definición formal como el contexto en el que aparece. Esto resulta esencial para desambiguar la función sintáctica que desempeña cada palabra en la oración.

Siguiendo con el ejemplo anterior, el etiquetado de los tokens daría como resultado: [‘Me’ → Pronombre, ‘gusta’ → Verbo, ‘programar’ → Verbo].

Análisis sintáctico

El análisis sintáctico examina la organización de las palabras dentro de una oración para verificar que se cumple con las reglas gramaticales del idioma. El objetivo fundamental de esta fase es la generación de un **árbol de análisis sintáctico**, el cual representa jerárquicamente la estructura gramatical del texto analizado. Esta representación estructurada permite a los sistemas computacionales interpretar las relaciones de dependencia y jerarquía entre los distintos elementos léxicos. Las tareas principales que abarca son:

- **Etiquetado gramatical:** Se fundamenta en el proceso de POS Tagging explicado en la fase de *Preprocesamiento y Tokenización*. En esta etapa de análisis sintáctico, las categorías morfológicas previamente asignadas a cada token se utilizan para validar la corrección de la estructura jerárquica de la oración.
- **Resolución de ambigüedad sintáctica:** Consiste en determinar la estructura gramatical correcta cuando una oración puede analizarse de múltiples formas. Por ejemplo, en la frase *Vi al hombre con el telescopio*, el sistema debe resolver si el telescopio es el instrumento utilizado por el sujeto para ver, o si es un objeto que lleva consigo el hombre.

Análisis semántico

Esta fase se centra en la coherencia lógica y la relevancia contextual del enunciado. Su objetivo principal es interpretar el significado de las palabras, analizando tanto su definición de diccionario como su variación según el contexto de uso. De este modo, se busca comprender el rol semántico de cada palabra para construir una representación lógica del mensaje. Las tareas fundamentales que abarca esta fase son:

1. **Named Entity Recognition (NER):** Se ocupa de la identificación y clasificación de elementos clave en el texto, tales como nombres de personas, ubicaciones geográficas, organizaciones, etc.
Ejemplo: En la oración *Mercedes anunció un nuevo coche en Berlín*, el sistema NER identificaría a *Mercedes* como una *Organización* y a *Berlín* como un *Lugar*.
2. **Word Sense Disambiguation (WSD):** Consiste en identificar el significado exacto de una palabra polisémica basándose en el contexto en el que se encuentra (proceso conocido como resolución de ambigüedad léxico-semántica).
Ejemplo: El término *banco* se interpreta como una *entidad financiera* en la frase *Fui a sacar dinero al banco*, pero adquiere el significado de *asiento* en la oración *Me senté en el banco del parque*.

Integración del discurso

Este proceso analiza cómo las oraciones individuales se conectan y relacionan entre sí para entender el contexto global. El objetivo de esta fase es garantizar que el significado del texto mantenga su coherencia lógica a través de los distintos párrafos y frases. Los aspectos fundamentales de esta fase son:

- **Resolución de anáforas:** Consiste en identificar la conexión entre un pronombre y lo mencionado previamente en el texto.
Ejemplo: En la secuencia *Esther fue a comprar. Ella compró fruta*, el sistema debe vincular el pronombre *Ella* con *Esther*.
- **Referencias contextuales:** Aborda la interpretación de palabras o expresiones cuyo significado completo depende intrínsecamente de la información proporcionada en oraciones anteriores o posteriores.
Ejemplo: La frase *Fue un buen día* adquiere un significado concreto únicamente si se analiza dentro del contexto de la conversación.

Análisis pragmático

Esta fase final analiza más allá de la interpretación literal de las oraciones para inferir el significado real que se pretende transmitir. A diferencia del

análisis semántico, que se ocupa del significado proposicional de las palabras, el análisis pragmático examina factores como el tono y el contexto. Las tareas principales de esta fase son:

- **Detección de intenciones:** El sistema debe ver el propósito de la comunicación (si es una petición, una queja, una orden, etc.).
Ejemplo: Ante la pregunta *¿Tienes hora?*, el análisis pragmático entiende que la intención real del usuario es saber qué hora es, no una pregunta de sí o no.
- **Interpretación de lenguaje figurado:** Se encarga de identificar metáforas, ironías o frases hechas.
Ejemplo: En la expresión *Echar una mano*, el análisis pragmático entiende que significa *ayudar a alguien*.

2.2. Computación cuántica

2.2.1. Números complejos

El conjunto de los números complejos, representado por el símbolo $\mathbb{C}$, es la combinación de números reales e imaginarios [13]. La parte real se puede expresar por un número entero o sus decimales, la parte imaginaria es aquella cuyo cuadrado es negativo.

Los números complejos sirven para dar sentido a la raíz cuadrada de números negativos. Esto permite que ecuaciones de segundo grado con discriminante negativo, puedan ser resueltas. Con esto se abre la puerta a un gran mundo en el que todas las operaciones (excepto dividir entre 0), son posibles.

Las características principales de los números complejos con las siguientes:

- Tiene distintas formas de expresarse.
- Dos números complejos se consideran iguales cuando tienen mismo componente real e imaginario.
- $\mathbb{C}$ conforma un espacio vectorial de dos dimensiones: la de los números reales y la de los imaginarios.
- Los números complejos no pueden mantener un orden. Es decir no se puede encontrar una propiedad $>$ o $<$ que un número para todos los números complejos.

Representación binómica

Un número complejo puede expresarse de forma puramente algebraica mediante su **representación binómica**. Esta forma divide el número en la suma de dos componentes:

$$z = a + bi, \quad a, b \in \mathbb{R}, \quad i = \sqrt{-1};$$

Con esta representación matemática, a constituye la **parte real** y b la **parte imaginaria** del número complejo. Si un número carece de parte real ($a = 0$), se le denomina imaginario puro.

A partir de la representación binómica de un número complejo se pueden definir a su vez otros dos números complejos fuertemente relacionados:

- **Conjugado:** Se define cambiando el signo de la parte imaginaria, denotándose como $\bar{z} = a - ib$.
- **Inverso:** Se define como $z^{-1} = \frac{a}{a^2+b^2} - \frac{b}{a^2+b^2}i$.

Al estar expresados en forma binómica, las operaciones aritméticas básicas entre dos números complejos $z_1 = a + bi$ y $z_2 = c + di$ se realizan aplicando las propiedades algebraicas de los números reales y teniendo en cuenta que $i^2 = -1$:

- **Suma y resta:** Se operan las partes reales e imaginarias por separado. Es decir, $z_1 \pm z_2 = (a \pm c) + (b \pm d)i$.
- **Multipliación:** Se aplica la propiedad distributiva convencional y se simplifica, obteniendo $z_1 \cdot z_2 = (ac - bd) + (ad + bc)i$.
- **División:** Para realizar $\frac{z_1}{z_2}$, se multiplica tanto el numerador como el denominador por el conjugado del denominador ($\bar{z}_2$). Esto elimina la parte imaginaria del divisor, permitiendo separar el resultado final en parte real e imaginaria.

Representación geométrica en $\mathbb{R}^2$

Debido a que la forma binómica de un número complejo $z = a + bi$ está unívocamente definida por dos valores reales (a y b), existe una correspondencia natural con el espacio bidimensional $\mathbb{R}^2$. Por ello, para representar gráficamente un número complejo, se utiliza un sistema de coordenadas cartesianas denominado **plano complejo** o plano de Argand [40].

Este plano está formado por dos ejes perpendiculares: un **eje real** (horizontal) donde se ubica la parte real a , y un **eje imaginario** (vertical) donde se posiciona la parte imaginaria b . De este modo, el número complejo puede representarse como el punto (a, b) en dicho plano. A este punto geométrico se le conoce formalmente como el **afijo** del número complejo.


EL PLANO COMPLEJO

Figura 2.2: Plano sobre como representar número complejo




Figura 2.3: Representación en plano sobre conjugado e inverso

La Figura 2.2 muestra cómo este punto se posiciona en el plano en base a sus componentes.

Basándonos en la definición del apartado anterior sobre el inverso y conjugado de un número complejo, al representarlo de forma gráfica queda de la siguiente manera:

Representación forma polar

Esta representación sirve para destacar los atributos gráficos que tienen los números complejos. Se basa en 2 conceptos fundamentales:

- **Módulo (r):** Distancia Euclidiana del afijo al origen de coordenadas, calculada como $r = |z| = \sqrt{a^2 + b^2}$.
- **Argumento (α o $\arg(z)$):** Ángulo que forma el segmento $\overline{OZ}$ con el semieje real positivo, se obtiene mediante $\alpha = \arctan\left(\frac{b}{a}\right)$.

En la Figura 2.4 se puede apreciar visualmente esta representación en el plano.




Figura 2.4: Gráfica de la forma polar de un número complejo

Utilizando estos dos parámetros, el número complejo z se puede expresar de una forma más compacta, conocida como **forma polar**, la cual se denota matemáticamente como:

$$z = r_{\alpha};$$

En base a la forma polar, se puede expresar z en **forma trigonométrica** de la siguiente manera:

$$z = r(\cos \alpha + i \operatorname{sen} \alpha);$$

Esta expresión permite la conversión de un número de su forma polar a su forma binómica ($z = a + bi$). Al distribuir el producto, se extrae explícitamente la correspondencia para cada una de las componentes cartesianas:

- **Parte real:** $a = r \cos \alpha$
- **Parte imaginaria:** $b = r \operatorname{sen} \alpha$

Operaciones La forma polar (y su equivalente trigonométrica) simplifica enormemente las operaciones de multiplicación y división. Para demostrarlo, consideremos dos números complejos cualesquiera explícitamente definidos en su **forma trigonométrica**: $z_1 = r(\cos \alpha + i \operatorname{sen} \alpha)$ y $z_2 = r'(\cos \beta + i \operatorname{sen} \beta)$.

Al operar con ellos matemáticamente, se obtienen los siguientes resultados:

- **Producto:** $z_1 \cdot z_2 = r \cdot r' (\cos(\alpha + \beta) + i \operatorname{sen}(\alpha + \beta))$

Se observa que el módulo del número complejo resultante es el producto de los módulos iniciales ($r \cdot r'$), y su argumento es la suma de los argumentos ($\alpha + \beta$).

- **Cociente:** $\frac{z_1}{z_2} = \frac{r}{r'} (\cos(\alpha - \beta) + i \operatorname{sen}(\alpha - \beta))$

El resultado del cociente es un número cuyo módulo es el cociente de los módulos $(\frac{r}{r'})$ y su argumento es la diferencia de los argumentos $(\alpha - \beta)$.

Por lo que en **forma polar** quedaría de la siguiente manera:

- **Producto:** $r_\alpha \cdot r'_\beta = (r \cdot r')_{\alpha+\beta}$

- **Cociente:** $\frac{r_\alpha}{r'_\beta} = (\frac{r}{r'})_{\alpha-\beta}$

Para calcular **potencia** con exponente natural **n**, en forma polar, hay que elevar el módulo a **n** y multiplicar el argumento por **n**.

$$(r_\alpha)^n = (r^n)_{n \cdot \alpha};$$

La **raíz n-esima** de un número complejo en forma polar, es otro número complejo m_β que debe de cumplir:

$$(m_\beta)^n = r_\alpha;$$

$$m = \sqrt[n]{r} \quad \text{y} \quad \beta = \frac{\alpha + 360^\circ \cdot k}{n} \quad \text{donde } k = 0, 1, 2, \dots, n-1;$$

Todo número complejo tiene n raíces n-ésimas. Todos los afijos están situados sobre una circunferencia y son los vértices de un polígono regular de n lados.

Un ejemplo de forma gráfica calculando la raíz n-esima con lo explicado anteriormente, es el que se ve en la Figura 2.5




Figura 2.5: Raíz 3-esima del número complejo $z = i + 1$

Representación en forma exponencial

Además de las representaciones binómica y polar, existe una tercera forma de expresar un número complejo que resulta de vital importancia en campos como la física y la computación cuántica. Gracias a la célebre **fórmula de Euler** [37], se establece una equivalencia matemática directa entre las funciones trigonométricas y la función exponencial compleja:

$$e^{i\alpha} = \cos \alpha + i \sin \alpha;$$

Si sustituimos esta identidad en la forma trigonométrica que vimos anteriormente ($z = r(\cos \alpha + i \sin \alpha)$), obtenemos la **forma exponencial** del número complejo:

$$z = re^{i\alpha};$$

Esta notación es extremadamente útil y será empleada junto con la notación de Dirac en la formulación de estados y operaciones cuánticas a lo largo de este trabajo, ya que simplifica de manera notable la representación algebraica de las rotaciones de fase y las operaciones matemáticas complejas.

Notación Dirac (Bra-Ket)

La notación de Dirac nos da una manera de expresar estados en un espacio vectorial sin atarnos a un sistema de coordenadas específico, pero que hace muy sencillo elegir una base concreta y cambiar de una base a otra.

En esta notación [36], un **ket** representa los valores como un vector columna, mientras que un **bra** los representa como un vector fila.

- **ket ($|a\rangle$):** Representa un vector columna cuyas componentes son números complejos. Si se tiene un vector $\vec{a} \in \mathbb{C}^n$, su representación en Dirac es el ket $|a\rangle$.

- **bra** ($\langle a|$): Representa el vector fila resultante de aplicar el conjugado transpuesto al ket correspondiente. Matemáticamente, se denota como $\langle a| = |a\rangle^\dagger$.

Por ejemplo, si consideramos un vector en el espacio bidimensional $\mathbb{C}^2$ con dos componentes complejas genéricas α y β , su representación en ket y su correspondiente bra serían:

- **ket:** $|\psi\rangle = \begin{pmatrix} \alpha \\ \beta \end{pmatrix}$
- **bra:** $\langle\psi| = |\psi\rangle^\dagger = (\alpha^* \ \beta^*)$

donde α^* y β^* son los complejos conjugados de α y β . Otro ejemplo fundamental en computación cuántica es la base canónica en $\mathbb{C}^2$, la cual se representa con los kets $|0\rangle$ y $|1\rangle$:

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix};$$

Utilizando esta notación, se puede definir las siguientes operaciones:

- **Producto interno:** Es un número obtenido al multiplicar un bra por un ket.

$$\langle a|b\rangle = (a_1^* \ a_2^*) \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = a_1^* b_1 + a_2^* b_2$$

- **Producto externo:** Resulta en una matriz, obtenida al multiplicar un ket por un bra. Si consideramos que los kets $|e_i\rangle$ forman una base ortonormal del espacio de Hilbert, el término $|e_i\rangle\langle e_j|$ representa una matriz con un 1 en la fila i y la columna j (y ceros en el resto). De este modo, cualquier matriz $\mathbf{A}$ se puede construir ponderando estas matrices base por sus respectivos coeficientes A_{ij} :

$$\mathbf{A} = \sum_{i,j=1}^N A_{ij} |e_i\rangle\langle e_j|$$

2.2.2. Qubits

Un Quantum Bit (Qubit) es el análogo cuántico al bit clásico [22]. Mientras el bit tiene **dos posibles estados**, el 0 y el 1, el Qubit se representa como un vector en el espacio vectorial $\mathbb{C}^2$. La base del espacio más utilizada, se denomina base computacional y se corresponde con la base canónica de $\mathbb{C}^2$, que en *notación de Dirac*, son los vectores $|0\rangle$ y $|1\rangle$:

$$\begin{aligned} |0\rangle &= \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in \mathbb{C}^2 \\ |1\rangle &= \begin{bmatrix} 0 \\ 1 \end{bmatrix} \end{aligned}$$

Un estado cuántico es la descripción matemática completa de un sistema cuántico aislado (en este caso, un Qubit). Más allá de ser un simple vector, este estado encapsula toda la información física y probabilística que podemos conocer del sistema antes de interactuar con él. Dado que se define dentro de un espacio de Hilbert, el estado cuántico obedece al *principio de superposición*, lo que le confiere la capacidad de existir en múltiples configuraciones clásicas de forma simultánea hasta que se produce el colapso mediante una medición.

Expresión del Qubit en Superposición

Gracias al principio de superposición mencionado anteriormente, un qubit $|\Psi\rangle$ no tiene por qué estar exclusivamente en el estado $|0\rangle$ o en el estado $|1\rangle$. En su lugar, su estado puede ser una **combinación lineal** de ambos vectores base. A este comportamiento se le denomina **superposición cuántica**, y permite que el qubit exista como una mezcla simultánea de ambos estados clásicos. En notación de Dirac, esto se representa algebraicamente como:

$$|\Psi\rangle = \alpha_0 |0\rangle + \alpha_1 |1\rangle;$$

Donde α_0 y α_1 son las **amplitudes de probabilidad**. De forma general, estas amplitudes se definen como números complejos (lo que, por definición matemática, también incluye a los números reales como un caso particular). Dado que estos coeficientes pueden tomar infinitos valores continuos, un qubit puede adoptar **infinitos** estados posibles, frente a los únicos dos valores (0 y 1) de un bit clásico. Para que este estado sea válido físicamente, su norma debe ser unitaria, asegurando que la suma de las probabilidades sea 1:

$$|\alpha_0|^2 + |\alpha_1|^2 = 1;$$

Cabe destacar que no existe una forma directa de determinar los valores exactos de α_0 y α_1 , ya que el estado cuántico interno no es directamente observable. Antes de realizar una medición, el qubit se encuentra en esta superposición inestable de los estados $|0\rangle$ y $|1\rangle$.

Para conocer el resultado de una computación cuántica, es necesario medir los qubits [43]. Sin embargo, el acto de medición implica una interacción física que perturba irreversiblemente el sistema. Esto provoca que el qubit abandone su estado de superposición y experimente el **colapso**. Al colapsar,

el qubit se ve forzado a tomar un único valor clásico definido, es decir, pasa a ser estrictamente un 0 lógico (estado $|0\rangle$) o un 1 lógico (estado $|1\rangle$). Una vez medido, el qubit se comporta como un bit clásico ordinario, y la información sobre sus amplitudes cuánticas originales se pierde de forma irrecuperable.

La probabilidad exacta de que el qubit colapse hacia un estado u otro está dictada por la **regla de Born**. Esta regla establece que la probabilidad de observar cada resultado clásico es igual al módulo al cuadrado de su amplitud correspondiente ($P(0) = |\alpha_0|^2$ y $P(1) = |\alpha_1|^2$).

La superposición, tiene distintas representaciones que son:

- **Binómica:** $|\Psi\rangle = (x_0 + iy_0) |0\rangle + (x_1 + iy_1) |1\rangle$
- **Exponencial:** $|\Psi\rangle = r_0 e^{i\phi_0} |0\rangle + r_1 e^{i\phi_1} |1\rangle$
- **Senos y cosenos:** $|\Psi\rangle = \cos\left(\frac{\theta}{2}\right) |0\rangle + e^{i\phi} \sin\left(\frac{\theta}{2}\right) |1\rangle$

Existen otros dos conceptos fundamentales relacionados con la superposición y sus fases complejas:

- **Fase global:** Factor común $e^{i\gamma}$ que multiplica a todo el estado $|\Psi\rangle$. Este no cambia ninguna probabilidad ni resultado físico.
- **Fase relativa:** Es la diferencia entre las amplitudes α y β . Esto influye a las inferencias y los resultados cuando se miden en otras bases (X, Y).

Esfera de Bloch

La esfera de Bloch es una representación visual del estado de un qubit. Cada punto sobre su superficie corresponde a una posible superposición de los estados base $|0\rangle$ y $|1\rangle$. Los polos superior e inferior representan los estados $|0\rangle$ y $|1\rangle$, respectivamente, y el estado del qubit se indica con una flecha que apunta hacia el punto que lo describe.




Figura 2.6: Visualización gráfica de la esfera de Bloch. Imagen obtenida de [50]

Importante: la notación $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ se corresponde con el vector estado $\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$ que a su vez significa:

$$\begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \frac{1}{\sqrt{2}}|0\rangle + \frac{1}{\sqrt{2}}|1\rangle;$$

Los seis puntos principales de la esfera de Bloch son los que se ve en la Figura 2.6 [10]. A estas coordenadas principales se le pueden asignar etiquetas.

- **Base de Hadamard:** También se le conoce como eje X de Pauli. El punto $\left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}\right)$ se corresponde con $|+\rangle$. A su vez, el punto opuesto $\left(\frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}}\right)$ se corresponde con $|-\rangle$
- **Base circular:** También se le conoce como eje Y de Pauli. El punto $\left(\frac{1}{\sqrt{2}}, \frac{i}{\sqrt{2}}\right)$ se corresponde con $|+i\rangle$. A su vez, el punto opuesto $\left(\frac{1}{\sqrt{2}}, \frac{-i}{\sqrt{2}}\right)$ se corresponde con $|-i\rangle$

Con dicha asignación de etiquetas, queda la esfera que se muestra en la Figura 2.7:




Figura 2.7: Imagen obtenida de [55]

Puertas cuánticas

Al igual que para manipular los valores de los bits existen puertas lógicas clásicas como OR, AND, NOT, etc. Los ordenadores cuánticos manipulan los valores de los qubits usando puertas cuánticas [47]. Esto implica que cualquier algoritmo cuántico se tiene que implementar usando puertas cuánticas.

Las puertas cuánticas se **representan** matemáticamente mediante **matrices unitarias** U [17]. Una matriz se considera unitaria si, al multiplicarla por su adjunta o conjugada transpuesta ($U^\dagger$), el resultado es la matriz identidad ($U^\dagger U = UU^\dagger = I$). Esta propiedad matemática es fundamental porque garantiza que la transformación es **reversible** y preserva la norma de los vectores. Esto significa que la puerta cuántica conserva siempre la probabilidad total de todos los posibles resultados, por lo que no se destruye ni se pierde información cuántica durante la operación.

Al aplicar una puerta cuántica U a un estado cuántico $|\psi\rangle$ se realiza la multiplicación matricial $|\psi'\rangle = U|\psi\rangle$. Si expresamos el nuevo estado resultante como $|\psi'\rangle = \alpha'_0|0\rangle + \alpha'_1|1\rangle$, la propiedad unitaria asegura que la norma siga siendo unitaria. Es decir, independientemente de la puerta cuántica que se aplique, la regla de conservación de probabilidad se mantiene intacta: $|\alpha'_0|^2 + |\alpha'_1|^2 = 1$.

Poniendo un ejemplo sencillo, consideremos la puerta Pauli-X (el análogo cuántico de la puerta NOT clásica), cuya matriz unitaria es $X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$. Si aplicamos esta puerta sobre el estado base $|0\rangle$, el estado transiciona a $|1\rangle$:

$$X|0\rangle = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix} = |1\rangle;$$

Como X es una matriz unitaria (y resulta ser su propia inversa, $X^\dagger X = I$), la operación es completamente reversible. Si aplicamos X por segunda vez, recuperamos matemáticamente el estado original $|0\rangle$ sin perder ninguna información en el proceso:

$$X(X|0\rangle) = X|1\rangle = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = |0\rangle;$$

Las puertas cuánticas para un único qubit son:

- **Pauli I (Identidad):** Se considera la operación trivial o identidad. Su función es dejar el qubit inalterado, y su operador asociado se denota mediante la matriz identidad I :

$$I = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix};$$

- **Pauli X:** Conocida coloquialmente como la puerta NOT cuántica. Algebraicamente se define por la siguiente matriz:

$$X = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix};$$

Al aplicar esta puerta, las amplitudes de probabilidad se intercambian, lo que provoca que los estados base $|0\rangle$ y $|1\rangle$ se inviertan.

- **Pauli Y:** Esta transformación combina una inversión de los estados con un cambio de fase complejo. Su estructura viene dada por:

$$Y = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix};$$

Si un qubit en superposición $|\psi\rangle = \alpha_0 |0\rangle + \alpha_1 |1\rangle$ atraviesa esta puerta, el efecto resultante es:

$$Y |\psi\rangle = \begin{bmatrix} 0 & -i \\ i & 0 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} = \begin{bmatrix} -i\alpha_1 \\ i\alpha_0 \end{bmatrix} = -i\alpha_1 |0\rangle + i\alpha_0 |1\rangle;$$

- **Pauli Z:** Actúa modificando únicamente la fase del estado $|1\rangle$ (añadiendo un desfase de π). Su operador matricial se expresa como:

$$Z = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix};$$

Matemáticamente, al operar sobre un qubit genérico $|\psi\rangle = \alpha_0 |0\rangle + \alpha_1 |1\rangle$, altera exclusivamente el signo de la segunda amplitud:

$$Z |\psi\rangle = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} = \begin{bmatrix} \alpha_0 \\ -\alpha_1 \end{bmatrix} = \alpha_0 |0\rangle - \alpha_1 |1\rangle;$$

- **Puerta Hadamard (H):** Es una de las operaciones más fundamentales, ya que al aplicarse sobre un estado base puro genera una superposición equitativa. Se define matricialmente como:

$$H = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix};$$

Si aplicamos esta transformación a un estado en superposición $|\psi\rangle = \alpha_0 |0\rangle + \alpha_1 |1\rangle$, las amplitudes se mezclan obteniendo la siguiente salida:

$$H |\psi\rangle = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} \alpha_0 + \alpha_1 \\ \alpha_0 - \alpha_1 \end{bmatrix} = \left(\frac{\alpha_0 + \alpha_1}{\sqrt{2}} \right) |0\rangle + \left(\frac{\alpha_0 - \alpha_1}{\sqrt{2}} \right) |1\rangle;$$

2.2.3. Procesamiento del Lenguaje Natural Cuántico

El procesamiento de datos clásicos utilizando algoritmos de aprendizaje automático a través de sistemas cuánticos, ha generado una línea de investigación de especial foco de interés estos últimos años. El QML se ha utilizado con distintos propósitos: profundizar en el uso de los fenómenos cuánticos para sistemas de aprendizaje, explorar la capacidad de los computadores cuánticos en aprender sobre datos cuánticos, y la posibilidad de reformular e implementar algoritmos de ML en hardware cuántico.

Como ocurrió anteriormente en el caso del ML clásico, el rápido crecimiento de los algoritmos de QML, tanto desde el lado del hardware como del software (en términos de dispositivos y algoritmos), ha involucrado al campo de PLN. Esto ha dado lugar al llamado PLNC, definido como la implementación del procesamiento del lenguaje natural en hardware cuántico.

Motivación para el uso de PLNC

La investigación del PLNC está motivada fundamentalmente por las limitaciones físicas y computacionales de los modelos clásicos ante la creciente complejidad del lenguaje, especialmente tras la aparición de los LLM. Los sistemas tradicionales requieren recursos masivos de tiempo y memoria para procesar grandes conjuntos de datos (corpus, como por ejemplo la Wikipedia). Además, los modelos PLN clásicos sufren degradación en precisión y fiabilidad al enfrentarse por ejemplo a la polisemia, es decir, cuando una palabra tiene distintos significados según el contexto, debido a las restricciones de las arquitecturas clásicas (frecuentemente basadas en estructuras de árbol) [18].

Para afrontar estos retos, el PLNC aprovecha fenómenos de la mecánica cuántica como la **superposición** y el **entrelazamiento**. Al operar en el espacio de *Hilbert*, esta arquitectura permite almacenar múltiples significados y contextos simultáneamente en un solo registro y ejecutar operaciones en paralelo. Esto no solo ofrece una ventaja exponencial acelerando la computación [52], sino que también proporciona una 'expresividad' superior, capturando las dependencias semánticas del lenguaje humano de una manera que los espacios numéricos clásicos replican con menor eficiencia.

No obstante, hay que tener en cuenta que, aunque teóricamente el PLNC puede resolver estos problemas, aún no se ha podido realizar una comparación a gran escala en hardware real (sin usar simuladores) frente a la computación clásica. Los modelos cuánticos actuales se han implementado sobre corpus pequeños, por lo que todavía no representan la escala completa que maneja un LLM moderno.

Codificación de información clásica en estados cuánticos

Una de las hipótesis fundamentales que motiva la intersección entre el procesamiento de lenguaje natural y la computación cuántica es la existencia de una relación estructural directa entre las características lingüísticas (sintáctica y semántica) y los estados cuánticos.

El framework Distributional Compositional Categorical (DisCoCat) [58] es el más conocido en formalizar esta relación. Nace de proponer la unificación de los dos enfoques clásicos del significado:

- **Distribucional:** Basado en la estadística y el contexto, que es la base de los vectores de palabras modernos.
- **Composicional:** Basado en la estructura gramatical, donde el significado de una frase depende de sus partes y de cómo se combinan (reglas sintácticas).

La relevancia de DisCoCat para el PLNC radica en que modela el lenguaje utilizando diagramas de palabras y productos tensoriales, una estructura matemática que es a la que describe a su vez la computación cuántica. Esto sugiere que los ordenadores cuánticos son, de manera nativa, idóneos para procesar el lenguaje natural.




Figura 2.8: Diagrama de la oración “Dani come pizza” en el formalismo DisCoCat.

En la Figura 2.8, las cajas representan el significado de las palabras que se transmiten mediante los “cables”, esto es similar a la técnica de Dependency Parse Tree (DPT) muy popular en la literatura lingüística. En la frase, el sujeto es “Dani”, mientras que “pizza” es el objeto, ambas palabras se relacionan mediante el verbo “come” y la combinación de estas palabras, crean el significado conjunto de la frase. Con DisCoCat, el significado de la oración se construye utilizando una gramática preagrupada mediante composición de productos tensoriales. Es decir, quedaría representado de la siguiente manera:

$$(\overrightarrow{\text{Dani}} \otimes \overrightarrow{\text{suj}}) \otimes \overrightarrow{\text{come}} \otimes (\overrightarrow{\text{pizza}} \otimes \overrightarrow{\text{obj}});$$

En esta expresión matemática:

- $\overrightarrow{\text{Dani}}$, $\overrightarrow{\text{come}}$ y $\overrightarrow{\text{pizza}}$ representan los vectores semánticos correspondientes a cada palabra individual.
- $\overrightarrow{\text{suj}}$ y $\overrightarrow{\text{obj}}$ son los vectores que codifican los roles sintácticos de sujeto y objeto, dictados por las reglas de la gramática.
- El operador $\otimes$ denota el producto tensorial, que es el mecanismo matemático que permite componer o entrelazar los significados léxicos con su función gramatical.

Todo este vector resultante generado en el espacio de productos tensoriales se puede considerar como el significado matemático de la oración completa “Dani come pizza”. Por ende, se dice que este framework lo ha expresado en términos afines a la computación cuántica.

Cabe destacar que, aunque el modelo DisCoCat original funciona perfectamente sin referencias explícitas a la teoría cuántica (a pesar de originarse en el formalismo de la Categorical Quantum Mechanics (CQM)). La novedad yace en el argumento de que el PLNC puede considerarse “nativo cuántico”. Esto se debe a que la teoría cuántica y el lenguaje natural comparten una misma estructura de interacción y el uso fundamental de espacios vectoriales para describir sus estados. Esta estructura de interacción determina por completo la estructura los procesos, incluyendo la especificación de los espacios donde “viven” los estados. Esta coincidencia estructural implica que el lenguaje natural podría encajar de manera más natural y eficiente en hardware cuántico que en hardware clásico.

Técnicas de codificación de datos clásicos a estados cuánticos Al igual que en computación clásica la información necesita ser codificada de manera que los modelos pueda entender los datos que se le proporcionan y así trabajar con ellos, la computación cuántica necesita poder codificar los datos de la computación clásica (texto en este caso, ya que estamos dentro del ámbito de PLN y PLNC), a estados cuánticos. Para ello existe diversas técnicas las cuales explicaremos a continuación:

- **Basis Encoding:** Utiliza n qubits. Complejidad $O(1)$. Simple, entradas cortas y simbólicas.
- **Angle Encoding:** Utiliza n qubits. Complejidad $O(n)$. Resiliente al ruido, vectores de características pequeños.
- **Amplitude Encoding:** Utiliza $\log_2(n)$ qubits. Complejidad $O(2^n)$. Eficiente en memoria, vectores de frases completas.

- **Hamiltonian Encoding:** Utiliza $\log_2(n)$ qubits. Complejidad $O(t)$. Estructura de grafos, análisis sintáctico (parsing), traducción.

De todas estas técnicas, se ha optado por implementar la técnica de *Basis Encoding* [42]. Este tipo de codificación se utiliza principalmente cuando un número real debe ser matemáticamente manipulado en un algoritmo cuántico. Su funcionamiento consiste en representar un número real como un número binario y luego transformarlo en un estado cuántico en la base computacional.

El estado cuántico embebido es la traducción bit a bit de una cadena binaria a los estados correspondientes de los subsistemas cuánticos. Por lo tanto, un bit de información clásica está representado por el estado de un subsistema cuántico. Actuar sobre características binarias codificadas como qubits otorga mayor flexibilidad computacional para diseñar algoritmos cuánticos.

Supongamos que queremos codificar la frase “María estudia medicina” utilizando *Basis Encoding*. Primero, definimos un vocabulario simplificado donde asignamos un índice entero único a cada palabra y fijamos una longitud de $\tau = 5$ bits por palabra (lo que permitiría un vocabulario de hasta $2^5 = 32$ palabras).

- *María* $\rightarrow$ Índice 3 $\rightarrow$ 00011
- *estudia* $\rightarrow$ Índice 12 $\rightarrow$ 01100
- *medicina* $\rightarrow$ Índice 21 $\rightarrow$ 10101

El vector de características de la frase corresponde entonces a la concatenación de estas secuencias binarias: $b = 00011\ 01100\ 10101$.

Finalmente, esta secuencia se representa mediante el estado cuántico conjunto en la base computacional:

$$|\psi\rangle_{\text{frase}} = |00011\rangle \otimes |01100\rangle \otimes |10101\rangle = |00011\ 01100\ 10101\rangle;$$

De esta forma, hemos codificado una frase de lengua clásica directamente en un estado cuántico en la base computacional.

Circuitos Variacionales Cuánticos como modelos de aprendizaje

En 2016, se tuvo acceso al primer ordenador cuántico en la nube, aunque el ruido y las limitaciones de qubits de las que se disponía hacía que fuera difícil implementar algoritmos cuánticos.

A pesar de estas limitaciones, se generó una gran expectación en la comunidad investigadora respecto al potencial que ofrecía esta nueva generación de dispositivos denominados Noisy Intermediate-Scale Quantum (NISQ).

Estos ordenadores contaban con entre 50 y 100 Qubits, lo que les permitía superar en rendimiento a los mejores superordenadores clásicos en determinadas áreas matemáticas [5, 61].

Los Circuitos Variacionales Cuánticos (CVC) nacieron como la mejor estrategia para hacer frente a los ordenadores NISQ. Debido a las limitaciones de estos dispositivos, se utilizó la estrategia de optimización basado en el aprendizaje. No son más que una analogía cuántica a las técnicas existentes del campo de ML como pueden ser las redes neuronales. En definitiva, son algoritmos cuánticos que tienen parámetros libres [35]. Al igual que cualquier otro circuito cuántico estándar, se necesita hacer uso de estos tres conceptos básicos:

1. Preparación con un **estado inicial** fijo.
2. Un **circuito cuántico** $U(\theta)$ parametrizado con un conjunto de parámetros libres θ .
3. **Medición** de un observable $\hat{B}$ en la salida. Este observable puede estar compuesto por varios observables, cada uno de manera local a un cable del circuito, o bien, a un conjunto de cables del circuito.

Para ilustrar estos tres conceptos de forma más intuitiva, imaginemos un sistema cuántico muy básico diseñado para clasificar el sentimiento de una frase (positivo o negativo):

- **1. Preparación:** Se recibe la información de entrada (por ejemplo, la frase “Me encanta”) y se codifica en el ordenador cuántico, alterando los qubits desde su estado base $|0\rangle$ hacia un estado que represente matemáticamente dicha frase.
- **2. Circuito parametrizado:** Actúa de forma análoga a las neuronas de una red neuronal clásica. Se aplican puertas lógicas cuánticas que dependen de unos ángulos θ . Durante el entrenamiento, el algoritmo irá ajustando estos parámetros θ para aprender a separar las frases positivas de las negativas.
- **3. Medición:** Tras el circuito, se miden los qubits resultantes. Podemos definir por ejemplo que si el sistema colapsa mayoritariamente en el estado $|0\rangle$, el sentimiento predicho es “positivo”, mientras que si colapsa en $|1\rangle$ es “negativo”.

Normalmente, los valores esperados $f(\theta) = \langle 0|U^\dagger(\theta)\hat{B}U(\theta)|0\rangle$ de uno o varios circuitos, definen un coste escalar para la tarea específica. Los parámetros libres $\theta = (\theta_1, \theta_2, \dots)$ son ajustados para optimizar esta función de coste, tal como se representa esquemáticamente en la Figura 2.9: el circuito recibe los parámetros, aplica las transformaciones unitarias, obtiene un




Figura 2.9: Coste de un Circuito Cuántico Variacional, imagen obtenida de: [35]

coste $f(\theta)$ mediante la medición del observable, y retroalimenta ese valor al optimizador clásico para actualizar θ en la siguiente iteración.

Los circuitos cuánticos variacionales son entrenados mediante un algoritmo de optimización clásico que realiza consultas al hardware cuántico. La optimización suele ser un esquema iterativo que busca mejores candidatos para los parámetros en cada paso.

Los parámetros variacionales θ , posiblemente junto con un conjunto adicional de parámetros no adaptables $x = (x_1, x_2, \dots)$, entran en el circuito cuántico como argumentos para las puertas del circuito. Esto nos permite convertir *información clásica* (los valores θ y x) en *información cuántica* (el estado cuántico $U(x; \theta)|0\rangle$). Como veremos en el ejemplo a continuación, los parámetros de puerta no adaptables suelen desempeñar el papel de *entradas de datos* en el aprendizaje automático cuántico.

Finalmente, la información cuántica se convierte de nuevo en información clásica evaluando el valor esperado del observable $\hat{B}$, tal y como se esquematiza en la Figura 2.10:

$$f(x; \theta) = \langle \hat{B} \rangle = \langle 0 | U^\dagger(x; \theta) \hat{B} U(x; \theta) | 0 \rangle .$$

En esta expresión, $U(x; \theta)$ representa el circuito cuántico parametrizado que transforma el estado base $|0\rangle$: los parámetros θ son los pesos entrenables del modelo, mientras que x son los datos de entrada no modificables (por ejemplo, la codificación cuántica de un texto). El operador $\hat{B}$ es el observable que se mide a la salida del circuito, y su valor esperado $\langle \hat{B} \rangle$ produce un escalar real que actúa como predicción del modelo para una tarea concreta (como la clasificación de sentimientos del ejemplo anterior).




Figura 2.10: Circuito variacional cuántico con parámetros modificables x y no modificables θ . Imagen obtenida de: [35]

Capítulo 3

Estado del arte

3.1. Representación Vectorial de Palabras (Word Embeddings)

Los word embeddings son una de las técnicas más usadas en PLN. Gracias a los word embeddings, existen lenguajes de modelo como GPT-3, GPT-4, etc.

Estos algoritmos son rápidos y pueden generar secuencias de lenguaje y realizar otras tareas derivadas con alta precisión, incluyendo la comprensión contextual, propiedades semánticas y sintácticas, así como la relación lineal entre las palabras.

En esencia, estos modelos aprenden a extraer y representar patrones complejos a partir de secuencias de texto o voz, capturando tanto el significado como las relaciones entre las palabras. Pero, ¿cómo lo hacen?

En las siguientes secciones se explorará en mayor profundidad los word embeddings así como conceptos más avanzados de estos.

3.1.1. Introducción al concepto de *Embedding*

De manera intuitiva, un *embedding* de texto es una representación matemática que proyecta un fragmento de texto en un espacio latente de alta dimensionalidad. En este espacio, la posición del texto se define mediante un vector, donde cada componente del vector corresponde a una dimensión. Al igual que en un plano cartesiano se tienen dos dimensiones, en un embedding, se suele trabajar con muchas más dimensiones para representar una palabra en el espacio[20]. Por ejemplo, el modelo de **OpenAI** *text-embedding-ada-002* el cual tiene un espacio de dimensión de 1536. Es decir, cada vector está formado por 1536 componentes.

Mostramos un ejemplo de cómo se verían los valores que toma cada dimensión es el siguiente:

“A text embedding is a piece of text projected into a high-dimensional

323.1. Representación Vectorial de Palabras (Word Embeddings)

latent space. The position of our text in this space is a vector, a long sequence of numbers. Think of the two-dimensional cartesian coordinates from algebra class, but with more dimensions—often 768 or 1536.” [20]

Al procesar el párrafo anterior mediante el modelo *text-embedding-ada-002* mencionado, se obtiene la gráfica de la Figura 3.1, donde cada barra vertical representa el valor asignado a una de sus 1536 dimensiones.




Figura 3.1: Representación gráfica de los valores en las 1536 dimensiones de un embedding generado por el modelo *text-embedding-ada-002*. Fuente: [20].

Un **espacio de embedding** o **espacio latente** se define matemáticamente como un espacio donde los elementos están posicionados de manera más cercana uno del otro cuando tienen valores parecidos, mientras que si difieren dichos elementos, se posicionan más lejos entre ellos. En el caso del PLN, frases que son semánticamente más similares a otras tendrán un vector de embedding similar, por lo que estarán más juntas en el espacio.

Aunque la comparación entre frases es una de las aplicaciones más conocidas, los *embeddings* también se aplica en modelos de ML y en arquitecturas de redes neuronales complejas.

Embeddings de palabras (*Word Embeddings*)

Mientras que el concepto general de *embedding* puede aplicarse a frases completas (como en el ejemplo introducido), su uso más extendido e histórico se encuentra en su aplicación a nivel atómico: las palabras. Un *embedding* de palabras, es un vector de longitud fija el cual su único cometido, es representar una única palabra o *token* [3].

El diseño y creación de estos vectores se clasifica principalmente en dos grandes familias estratégicas, dependientes de sus algoritmos de generación: los **modelos basados en predicciones** y los **modelos basados en conteos**.

Modelos basados en predicciones Esta técnica de representación surgió fuertemente ligada al desarrollo de los Modelo Neuronal del Lenguaje (MNL). A diferencia de los enfoques estadísticos tradicionales de recuento, un modelo predictivo se centra en aprender el significado de un término de forma prospectiva, es decir, “adivinando”.

Para lograrlo, emplean una red neuronal sencilla dotada de una ventana de contexto de tamaño fijo y móvil (por ejemplo, avanzando de cinco en cinco palabras). A medida que lee el texto, el modelo intenta predecir el significado de una palabra central en base a las palabras vecinas de esta ventana, o a la inversa, predecir el contexto apoyándose únicamente en dicho término central.

El aspecto fundamental en todo esto, es que tras finalizar el entrenamiento, el objetivo de ML deja de ser la capacidad del modelo para adivinar con exactitud. En su lugar, de la red neuronal, se extraen los **pesos y valores** que ha ajustado internamente. Estos valores que fueron ajustados durante el entrenamiento se convierten directamente en el *word embedding*. En consecuencia, el mecanismo iterativo garantiza que aquellas palabras empleadas en contextos idénticos acaben reteniendo representaciones vectoriales prácticamente iguales, tal y como se muestra en la Figura 3.2.




Figura 3.2: Representación visual de un modelo basado en predicciones para generar *embeddings* de palabras. Fuente: [32].

Una de las arquitecturas más representativas dentro de la predicción de *embeddings* es la famosa familia algorítmica **Word2Vec**, en concreto **SkipGram** que se detalla de forma exhaustiva en el próximo capítulo.

Modelos basados en conteos Por su parte, la segunda categoría de modelos hace uso de la estadística global a lo largo de un documento completo (*corpus*). Estos modelos se aprovechan de los recuentos de coocurrencia (palabra y contexto) estructurando toda la información como grandes *matrices de palabra-contexto*.

343.1. Representación Vectorial de Palabras (Word Embeddings)

El funcionamiento radica en la creación de una matriz gigantesca donde se contabiliza el número de apariciones conjuntas en las que una palabra acompaña a todo un posible contexto del propio texto. No obstante, si el conjunto de datos cuenta con n palabras distintas, las dimensiones de la matriz ascenderán a un total de $n \times n$. Esto acarrea severamente un cuello de botella de almacenamiento. Adicionalmente, la inmensa mayoría de cruces de dicha matriz representarán palabras que jamás han coexistido en el texto (por ejemplo, “oveja” y “pantalla”), llenando de ceros el modelo de datos. Esta estructura tan ineficiente es conocida como **matriz dispersa**.

Para solventar esta carencia y la falta de memoria, se reduce la dimensionalidad a través de complejas operaciones de álgebra lineal, como puede ser la Descomposición en Valores Singulares (DVS). Con esto logran sintetizar enormes matrices de ceros, transformándolos en **vectores cortos y densos**. De tal modo, que los conceptos globalmente equivalentes retengan valores numéricamente similares sin desperdiciar memoria.

La **mayor ventaja** de esta táctica estadística contable, frente al sistema predictivo, reside precisamente en que es capaz de aprovechar la información global de todo el *corpus*, un aspecto estadístico que se le escapa a las ventanas de lectura en las redes neuronales por definición.

El modelo híbrido con más popularidad en este ámbito es el de **GloVe (Global Vectors)** [34]. Desarrollado por un equipo de investigadores de la Universidad de Stanford, logra exitosamente agrupar los beneficios numéricos de las matrices grandes de conteo global, con las altas capacidades de optimización paramétrica propias de los modelos del ML, como se ilustra en la Figura 3.3.

3.1.2. Mecanismos geométricos de los embeddings

Una vez comprendido que un embedding proyecta palabras en un espacio continuo donde la cercanía espacial equivale a similitud semántica, surgen dos interrogantes fundamentales en el diseño de estos sistemas: ¿cómo se estructuran los ejes de este espacio para encapsular el significado complejo del lenguaje? y ¿cómo se calcula con precisión matemática la distancia entre dos vectores?

Para responder a la primera cuestión, es necesario analizar el papel de la **información latente** [20], la cual permite pasar de representaciones dispersas a vectores densos basados en atributos ocultos. Para la segunda, se debe explorar **métricas de distancia** específicas que sean efectivas en espacios de tantas dimensiones.

Métricas de Distancia

Como se explicó con anterioridad, una de las características principales de un embedding representado en el espacio, es que mantiene la distancia.

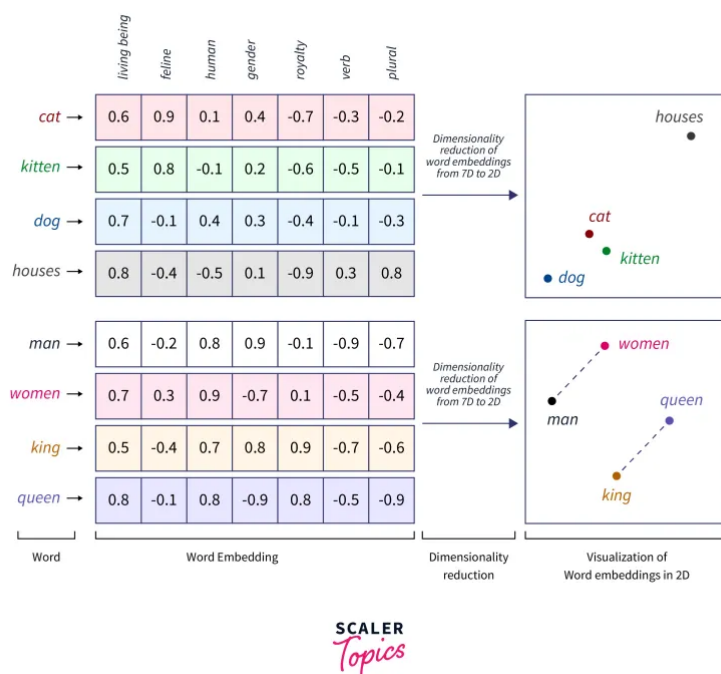


Figura 3.3: Representación visual de un modelo basado en conteos para generar embeddings de palabras. Fuente: [27].

Los vectores de alta dimensionalidad que se utilizan en los embeddings de palabra (así como en los LLMs), no son intuitivos. Pero la intuición espacial se mantiene igual mientras reducimos la escala de estos.

Un ejemplo básico es el siguiente: imagina un plano de planta bidimensional de una biblioteca de una sola planta. Los usuarios de la biblioteca son amantes de los gatos, de los perros, o se sitúan en algún punto intermedio. El objetivo es colocar los libros sobre gatos cerca de otros libros de gatos, y los libros sobre perros cerca de otros libros de perros.

El enfoque más sencillo se conoce como el modelo de bolsa de palabras. Consiste en establecer un eje de perros a lo largo de una pared y un eje de gatos perpendicular a él. A continuación, se cuentan las ocurrencias de las palabras “gato” y “perro” en cada libro y se ubica dicho libro en su punto correspondiente dentro del sistema de coordenadas ($\text{perro}_x, \text{gato}_y$).

Pensemos ahora en un sistema de recomendación sencillo. A partir de la selección anterior de un libro, ¿qué se podría sugerir a continuación? Bajo la suposición (muy simplificada) de que estas dos dimensiones capturan adecuadamente las preferencias del lector, basta con buscar el libro que se encuentre más cerca. En este caso, el sentido intuitivo de cercanía es la

363.1. Representación Vectorial de Palabras (Word Embeddings)

distancia euclídea —el camino más corto entre dos libros—:

$$d(\mathbf{p}, \mathbf{q}) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2};$$

Siguiendo el razonamiento lógico, si se analiza a través de la distancia euclídea, se pondrá el libro (perro₅, gato₁) más cerca del libro (perro₁, gato₅) que de un libro mucho más extenso o enciclopédico como (perro₁₀₀, gato₁). Esto plantea un grave problema semántico: un lector de libros cortos de perros con proporción (5, 1) seguramente prefiera a continuación una enciclopedia gigante sobre perros de (100, 1) antes que un libro corto sobre gatos de (1, 5). La métrica euclídea penaliza severamente la longitud en palabras del libro (magnitud) omitiendo por completo el reparto del tema de este (la proporción).

Cuando resulta más relevante concentrarse en los pesos relativos temáticos que en sus magnitudes absolutas, los vectores se normalizan. Esto se logra dividiendo en ambos la cantidad de apariciones de perros y gatos para obtener la conocida **similitud coseno** [38]. De manera más visual, este cálculo equivale geométricamente a proyectar todos los puntos disponibles en el espacio sobre una circunferencia de radio unidad (es decir, que el módulo de todos los vectores es 1) y medir la distancia a lo largo del arco que los une. Al ignorar la longitud del documento original, se evalúa únicamente la dirección del vector respecto al origen, logrando una métrica de similitud mucho más robusta y natural al lenguaje humano.

Matemáticamente, esta métrica se define mediante el cociente del producto escalar de dos determinados vectores entre el producto de sus magnitudes:

$$\text{similitud}(\mathbf{p}, \mathbf{q}) = \cos(\theta) = \frac{\mathbf{p} \cdot \mathbf{q}}{\|\mathbf{p}\| \|\mathbf{q}\|} = \frac{\sum_{i=1}^n p_i q_i}{\sqrt{\sum_{i=1}^n p_i^2} \sqrt{\sum_{i=1}^n q_i^2}};$$

Un pensamiento intuitivo para entender la fórmula de similitud coseno, es que si dos vectores apuntan en la misma dirección, el ángulo entre ellos es 0 por lo que el coseno es 1. Si son ortogonales, significa que no comparten una 'direccionalidad', el coseno es 0.

En el contexto que nos encontramos de embeddings de palabras, hay que pensar que cada vector actúa como una flecha que apunta desde el origen hasta la posición de la palabra en nuestra librería imaginada. Palabras que son similares semánticamente tendrán vectores que apuntan en direcciones similares, es decir, la similitud coseno será mayor, tal y como se puede apreciar gráficamente en la Figura 3.4.




Figura 3.4: Ejemplo visual de la representación de vectores y su cercanía empleando la similitud coseno. Fuente: [24].

Información Latente

Cualquier texto suele emplear sinónimos o términos relacionados para referirse a un mismo concepto; por ejemplo, volviendo al mismo ejemplo de antes, un libro sobre perros utilizará frecuentemente palabras como “canino”. En un modelo básico de bolsa de palabras, incorporar este nuevo vocablo requiere añadir una dimensión perpendicular adicional a las ya existentes, transformando nuestro anterior sistema de coordenadas en $(\text{perro}_x, \text{gato}_y, \text{canino}_z)$.

Bajo este mismo principio, resulta muy sencillo continuar agregando nuevas dimensiones para representar más palabras, consiguiendo un espacio multidimensional $(\text{perro}_x, \text{gato}_y, \text{canino}_z, \text{felino}_w)$. Sin embargo, este enfoque tan básico conlleva dos grandes problemas que imposibilitan su aplicación a gran escala: rompe de inmediato la interpretabilidad espacial (como lo era la sencilla idea inicial de una biblioteca bidimensional) y provoca una explosión en los requisitos necesarios para el cómputo.

Resulta evidente que, a nivel computacional, esta aproximación es extremadamente ineficiente a medida que aumenta el tamaño del vocabulario. El español, por ejemplo, cuenta con más de 93.000 palabras según el Diccionario de la Real Academia Española [12]. Manejar vectores con decenas de miles de dimensiones implica calcular una ingente cantidad de combi-

383.1. Representación Vectorial de Palabras (Word Embeddings)

natorias. Además, se agrava el problema de la dispersión de datos: en un documento dado, la gran mayoría del vocabulario total no aparecerá, rellenando los vectores con innumerables ceros que penalizan drásticamente el rendimiento de los modelos estadísticos y de aprendizaje automático.

La solución a la alta dimensionalidad radica en abstraer el conteo literal hacia ejes que representen verdaderos atributos semánticos. Si el modelo es capaz de identificar la relación semántica entre “gato” y “felino”, podría agrupar la contribución de ambas en una única variable latente compartida. Esto no solo comprime el tamaño de los vectores, haciendo a los algoritmos mucho más eficientes y veloces, sino que también genera una representación geométrica mucho más afín a la intuición humana.

De la misma forma, términos más amplios como “mascota” o “mamífero” representan características semánticas compartidas simultáneamente por “perro” y “gato”. En un espacio latente bien optimizado, estas palabras genéricas actúan como atributos comunes que vinculan y aproximan ambos animales en ciertas dimensiones del espacio. Por otro lado, si la elevada reducción dimensional provocara una superposición excesiva donde términos que debieran ser distintos terminen colapsando —por ejemplo, confundándose ambos en el mismo punto exacto—, esta carencia de precisión podría mitigarse introduciendo nuevos ejes latentes. Estos nuevos atributos ocultos de diferenciación (por ejemplo, proyectando qué palabras se relacionan estrechamente con “mesa” frente a los animales vivos mencionados anteriormente) permiten desenredar los agrupamientos de datos semánticos complejos.

3.1.3. Paralelismo entre Espacio Semántico y Espacio de Hilbert

Como se vio en capítulos anteriores, los estados en computación cuántica están representados por vectores definidos en un espacio complejo, el cual se conoce formalmente como **espacio de Hilbert** ($\mathcal{H}$) [39]. Por su parte, en el PLN clásico se modela el significado de las palabras mapeándolas a vectores en un espacio vectorial puramente real ($\mathbb{R}^n$).

A partir de esta analogía natural, surge la posibilidad de modelar las palabras y sus significados como estados dentro del propio espacio de Hilbert [57].

Codificación multidimensional: Forma y Contenido

En un espacio semántico tradicional, el significado de una palabra adquiere “sustancia” al ubicarse en unas coordenadas determinadas que definen su forma. Sin embargo, al restringirse al uso exclusivo de los números reales, el PLN clásico queda comúnmente limitado a capturar únicamente su *semántica distribucional* (las estadísticas y frecuencias con las que coocurre

junto a otras palabras).

Al trasladar el procesamiento de lenguaje al dominio cuántico de Hilbert, las propiedades exclusivas de los números complejos permiten unificar distintos niveles de información semántica en un único vector de estado. Esto logra vincular el uso externo del lenguaje (su *forma*) directamente con su fundamento conceptual intrínseco (su *contenido*). Para ello, se propone una división explícita de las dimensiones de almacenamiento:

- **Componente Real:** Se utiliza de la misma forma para codificar la *semántica distribucional*. Captura el uso estadístico clásico, determinando el comportamiento de la palabra estrictamente en base a su contexto y al número de interacciones o apariciones que realiza con respecto a las palabras que le rodean en los distintos documentos analizados.
- **Componente Imaginaria:** Se reserva de forma ortogonal para alojar la *semántica referencial u ontológica*. Representa los fundamentos preexistentes, los conceptos formales o el núcleo estricto que designa la propia palabra (el significado que podría extraerse de ontologías taxonómicas u organizaciones como base de conocimientos, por ejemplo *WordNet* o diagramas *SNOMED-CT*).

Esta división entre semántica distribucional y referencial, y cómo ambas conviven en el mismo espacio vectorial complejo, queda representada esquemáticamente en la Figura 3.5.




Figura 3.5: Esquema del espacio documental complejo vectorial unificando la semántica distribucional y referencial en el espacio de Hilbert. Fuente: [57].

Afinidad Cuántica, Superposiciones y Fases

En el apartado clásico se demostró que la afinidad semántica puede medirse mediante distintas distancias sobre un espacio real continuo. No obstante, al emplear el espacio de Hilbert esta medición no solo relaciona dos

palabras distintas, sino que va un paso más allá. Al tratar con números complejos, es posible medir la distancia cuantitativa que existe entre la parte estadística de uso de la palabra (su componente real) y su definición conceptual referencial alojada en su componente imaginaria.

Para este análisis se evalúa la **fase o ángulo** que se forma interactivamente entre ambas componentes, logrando que el producto interno refleje tanto la componente real como imaginaria del contenido.

3.2. Implementación Clásica: Algoritmo Word2Vec

Word2Vec, cuyo nombre proviene de la contracción de *Word to Vector*, es un modelo de ML que permite representar palabras como vectores de grandes dimensiones. Su principal virtud reside en que las relaciones semánticas y sintácticas entre palabras quedan codificadas como proximidad geométrica entre dichos vectores, permitiendo así capturar el significado de forma numérica y operable.

Fue desarrollado y publicado por Google en 2013 [16], además en esa misma fecha, se introdujo este modelo en su motor de búsqueda. Desde entonces, el modelo ha sido ampliamente adoptado y ha dado lugar a múltiples mejoras y variantes de rendimiento.

En este capítulo se explorarán la arquitectura del modelo, su función de optimización y el proceso de entrenamiento que permite generar el espacio vectorial latente en el que las palabras quedan representadas.

3.2.1. Arquitectura del modelo

Word2Vec aprende las representaciones de las palabras procesando grandes volúmenes de texto y capturando el contexto en el que aparece cada término [26]. Su arquitectura se fundamenta en una red neuronal superficial (*shallow neural network*), que a diferencia de las redes profundas (*deep neural networks*), dispone únicamente de una capa oculta entre la capa de entrada y la de salida, tal como se ilustra en la Figura 3.6. Este diseño proporciona una ventaja clave: permite entrenar el modelo de forma eficiente sobre corpus de gran tamaño, manteniendo un coste computacional razonable.

El resultado del entrenamiento es la asignación de un vector de cientos de dimensiones a cada palabra del vocabulario. La posición de cada vector en ese espacio no es arbitraria: palabras empleadas en contextos similares acaban próximas entre sí, mientras que palabras semánticamente distantes se alejan geoméricamente, como puede observarse en la Figura 3.7.

Una consecuencia directa de esta estructura es que los vectores admiten operaciones algebraicas con significado semántico. El ejemplo más conocido de esta propiedad es la siguiente analogía entre género y realeza:




Figura 3.6: Comparativa entre una red neuronal superficial (Word2Vec) y una red neuronal profunda. Fuente: [26].

$$\vec{v}(\text{Rey}) - \vec{v}(\text{Hombre}) + \vec{v}(\text{Mujer}) \approx \vec{v}(\text{Reina});$$

En esta expresión, al restar al vector de *Rey* la componente que codifica la masculinidad y sumar la que codifica la feminidad, el vector resultante converge hacia la representación de *Reina*. Esta propiedad es inherente a la forma natural del entrenamiento: como *Rey* y *Reina* comparten contextos de realeza pero difieren en los contextos de género, el modelo aprende implícitamente a separar ambas dimensiones dentro del espacio vectorial, tal y como se aprecia visualmente en la Figura 3.8.

Modelos de entrenamiento: CBOW y Skip-gram

Word2Vec ofrece dos variantes arquitectónicas para aprender los vectores de palabras: el modelo **Continuous Bag of Words (CBOW)** y el modelo **Skip-gram**. Ambos comparten la misma red neuronal superficial como base, pero se diferencian en el aprendizaje, en lo que se usa como entrada y en lo que se predice como salida.

En este trabajo se ha optado por implementar el modelo **Skip-gram**, ya que, como se verá en los capítulos siguientes, sus características lo hacen especialmente adecuado para la adaptación al entorno cuántico propuesto.

Continuous Bag of Words (CBOW) El modelo CBOW toma como entrada las palabras del contexto que rodean a una posición central y predice cuál es la palabra que debería ocupar dicha posición. En otras palabras, dadas las palabras vecinas, el modelo intenta adivinar la palabra central, como se muestra en la Figura 3.9.




Figura 3.7: Representación vectorial de palabras en el espacio latente generado por Word2Vec. Fuente: [26].

Este enfoque resulta eficiente cuando el corpus es grande y las palabras frecuentes tienen representaciones ricas. Sin embargo, tiende a promediar la información del contexto, lo que puede penalizar los valores semánticos de palabras menos frecuentes generando así una pérdida de información.

Skip-gram Skip-gram es un modelo diseñado para hacer lo opuesto a CBOW. En lugar de predecir la palabra central a partir del contexto que tiene en su ventana, toma una única palabra central como entrada e intenta predecir las palabras que aparecen a su alrededor.

El proceso de entrenamiento de esta red neuronal superficial funciona de la siguiente manera: dada la palabra central (la palabra de entrada), se selecciona aleatoriamente una palabra de su contexto inmediato. La red calcula cuál es la probabilidad de que cada palabra del vocabulario sea una palabra “cercana” a la palabra de entrada [28].

Los resultados de estas probabilidades indican cuán probable es que cada término del vocabulario aparezca en las proximidades de la palabra de entrada. Por ejemplo, si la palabra de entrada proporcionada a la red ya entrenada es *reino*, las probabilidades serán considerablemente mayores para palabras como *España* o *Inglaterra* que para términos sin relación semántica como *lápiz* o *mango*.

Detalles del modelo básico Skip-gram Dado que una red neuronal no puede procesar cadenas de texto directamente, cada palabra se representa mediante un *vector one-hot* (una forma de codificación sencilla aunque no la única). Consiste en un vector de tantas componentes como palabras tiene el vocabulario (por ejemplo, 10.000), donde únicamente la posición correspondiente a la palabra de entrada vale 1 y el resto valen 0.




Figura 3.8: Representación geométrica de las similitudes semánticas entre palabras en el espacio vectorial de Word2Vec. Fuente: [26].

La capa de salida de la red produce también un vector de 10.000 componentes, donde cada valor refleja la probabilidad de que la palabra correspondiente sea una palabra cercana a la entrada. No existe función de activación en la capa oculta, pero la capa de salida aplica *softmax* para normalizar las probabilidades. Esta arquitectura completa puede observarse en la Figura 3.10.

Durante el entrenamiento, tanto la entrada como la salida de la red son vectores *one-hot*. Sin embargo, al evaluar la red con una palabra de entrada, el vector de salida ya no es *one-hot*, sino una distribución de probabilidad sobre todo el vocabulario.

A modo de ejemplo concreto, supóngase que la **capa oculta** aprende vectores de palabras de 300 dimensiones. En ese caso, los pesos de dicha capa quedan representados por una matriz de 10.000×300 : una fila por cada palabra del vocabulario y una columna por cada neurona oculta. Este es precisamente el tamaño que empleó Google en el trabajo original en el que presentó Word2Vec [16].

Al final, el objetivo de este modelo es aprender la matriz de pesos de la capa oculta, cuya estructura se ilustra en la Figura 3.11. Una vez se tiene esta matriz, la capa de salida es inmediata.

Llegados a este punto, uno puede preguntarse cuál es la utilidad de representar las palabras mediante vectores de todo menos una única posición con valor 1. La respuesta reside en la eficiencia: multiplicar un vector *one-hot* de 1×10.000 por la matriz de 10.000×300 selecciona de forma inmediata la fila correspondiente a la palabra de entrada, sin necesidad de realizar el producto matricial completo, tal y como se muestra en la Figura 3.12.

Con esto se concluye que la capa oculta del modelo actúa en realidad

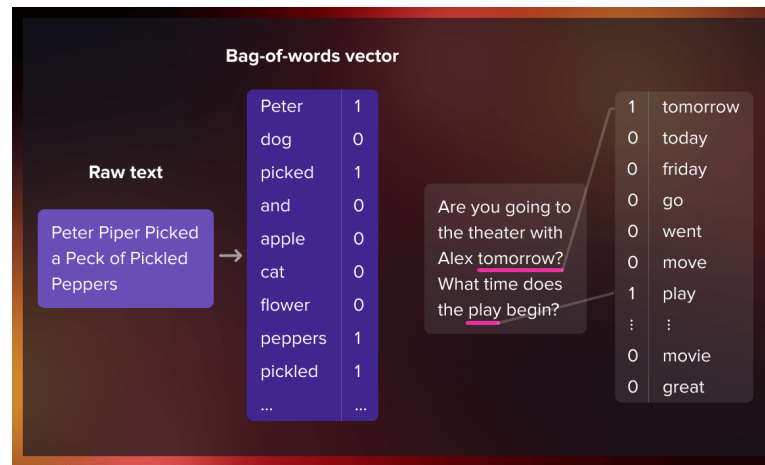


Figura 3.9: Ejemplo del funcionamiento del modelo CBOW: a partir de las palabras de contexto circundantes se predice la palabra objetivo central. Fuente: [26].

como una tabla *lookup*: la salida de dicha capa es directamente el vector de representación de la palabra de entrada. Así, el vector de 1×300 resultante se pasa a la **capa de salida**, que es un clasificador de regresión *softmax*.

Cada neurona de salida produce un valor entre 0 y 1 aplicando la función $\exp(x)$ sobre el producto de su vector de pesos y el vector proveniente de la capa oculta. Para que todos los valores sumen 1 y formen una distribución de probabilidad, cada resultado se divide entre la suma de los valores de las 10.000 neuronas de salida [28], tal y como se aprecia en la Figura 3.13.

Mejoras aplicadas al modelo básico Skip-gram Retomando el ejemplo anterior, con 300 dimensiones y un vocabulario de 10.000 palabras, la red neuronal dispone de dos matrices de pesos: una correspondiente a la capa oculta y otra a la capa de salida. Cada una de ellas contiene un total de $300 \times 10.000 = 3$ millones de parámetros. Para ajustar correctamente este volumen de parámetros y evitar al mismo tiempo el sobreajuste se debe disponer de conjuntos de datos de entrenamiento de gran tamaño, lo que convierte el entrenamiento del modelo básico en un proceso computacionalmente costoso.

Para abordar este problema, Google publicó un segundo artículo [31] en el que se proponían dos innovaciones clave sobre el modelo básico:

- **Submuestreo de palabras frecuentes:** se reduce la frecuencia con la que las palabras muy comunes participan en el entrenamiento, disminuyendo así el número total de ejemplos procesados.
- **Negative Sampling:** se sustituye la función de optimización original (descenso del gradiente) por una alternativa más eficiente que, en lugar




Figura 3.10: Arquitectura de la red neuronal del modelo Skip-gram. Fuente: [28].

de actualizar todos los pesos de la red en cada iteración, únicamente modifica un subconjunto reducido de ellos.

Estas dos mejoras demostraron que, lejos de comprometer la calidad del modelo, se conseguía una reducción del coste computacional. Además de una mejora de la calidad de los vectores de palabras resultantes. Dado que en la implementación práctica de este trabajo se ha empleado el *Negative Sampling* como función de optimización, su funcionamiento se describe en detalle en la sección siguiente.

3.2.2. Función de optimización

Para comprender la mejora que introduce el *Negative Sampling*, es necesario partir de la formulación matemática original del modelo básico de Skip-gram y, a partir de ella, entender qué limitaciones motivan la adopción de esta nueva función de optimización [51].

El objetivo principal de Skip-gram es maximizar la probabilidad logarítmica promedio sobre todo el corpus de entrenamiento, lo que queda expresado mediante la siguiente fórmula:

$$\frac{1}{T} \sum_{t=1}^T \sum_{\substack{-c \leq j \leq c \\ j \neq 0}} \log p(w_{t+j} | w_t);$$

donde:




Figura 3.11: Matriz de pesos de la capa oculta del modelo Skip-gram: 10.000 filas (una por palabra del vocabulario) y 300 columnas (una por neurona oculta). Cada fila constituye el vector de representación de su palabra correspondiente. Fuente: [28].

$$\begin{bmatrix} 0 & 0 & 0 & 1 & 0 \end{bmatrix} \times \begin{bmatrix} 17 & 24 & 1 \\ 23 & 5 & 7 \\ 4 & 6 & 13 \\ 10 & 12 & 19 \\ 11 & 18 & 25 \end{bmatrix} = \begin{bmatrix} 10 & 12 & 19 \end{bmatrix}$$

Figura 3.12: Multiplicación de un vector one-hot por la matriz de pesos de la capa oculta, obteniendo directamente el vector de representación de la palabra de entrada. Fuente: [28].

- c es el tamaño de la ventana de contexto. Valores más altos de c generan más ejemplos de entrenamiento y, por tanto, ofrecen mayor precisión, aunque a costa de un tiempo de entrenamiento superior.
- T es el número total de palabras del corpus de entrenamiento.
- w_t es la palabra de entrenamiento en la posición t .

La probabilidad condicional $p(w_{t+j} | w_t)$ del modelo básico de Skip-gram se define mediante la función *softmax* de la siguiente forma [51]:

$$p(w_O | w_I) = \frac{\exp(v'_{w_O} \top v_{w_I})}{\sum_{w=1}^W \exp(v'_w \top v_{w_I})};$$

donde v_w y v'_w son, respectivamente, los vectores de representación de




Figura 3.13: Cálculo de la salida de la neurona correspondiente a la palabra car en la capa softmax del modelo Skip-gram. Fuente: [28].

entrada y de salida de la palabra w , y W es el número total de palabras del vocabulario.

Esta formulación presenta un problema de escalabilidad: el coste de calcular $p(w_O \mid w_I)$ es proporcional a W , cuyo valor suele ser muy elevado (entre 10^5 y 10^7 términos). Ello implica que, en el denominador del *softmax*, es necesario acumular los valores exponenciales de todas las palabras del vocabulario en cada paso de entrenamiento, lo que hace que el proceso resulte prohibitivamente lento cuando el vocabulario es de gran escala. Es precisamente este coste el que motiva la introducción del *Negative Sampling* como función de optimización alternativa.

Esta nueva función de optimización persigue maximizar la similitud entre las palabras que aparecen en el mismo contexto y minimizarla cuando proceden de contextos distintos. Sin embargo, en lugar de aplicar esa minimización sobre todas las palabras del corpus, selecciona aleatoriamente k palabras, denominadas *muestras negativas*, y las emplea para optimizar la función objetivo [23]. La expresión de dicha función es la siguiente:

$$\log \sigma(v'_{w_O} \top v_{w_I}) + \sum_{i=1}^k \mathbb{E}_{w_i \sim P_n(w)} \left[\log \sigma(-v'_{w_i} \top v_{w_I}) \right];$$

donde σ es la función sigmoide y $P_n(w)$ es la distribución de ruido a partir de la cual se extraen las muestras negativas. Esta distribución se calcula como la distribución unigrama de las palabras elevada a la potencia $\frac{3}{4}$, exponente elegido empíricamente en el trabajo original donde se introduce este algoritmo [31]:

$$P_n(w) = \frac{U(w)^{\frac{3}{4}}}{Z};$$

donde $U(w)$ es la frecuencia de aparición de la palabra w en el corpus y Z es la constante de normalización que garantiza que la distribución sume 1.

Maximizar esta expresión conlleva maximizar el producto escalar en su primer término y minimizarlo en el segundo. Dicho de otra manera, las palabras que aparecen en el mismo contexto se ven forzadas a adquirir represen-

taciones vectoriales más similares entre sí, mientras que las que pertenecen a contextos distintos se ven forzadas a tener vectores menos similares [23].

En cuanto a la elección del hiperparámetro k , el segundo artículo de Google sobre Word2Vec [31] indica que un valor en el rango de 5 a 20 es adecuado para corpus de entrenamiento de tamaño reducido, mientras que para corpus de gran escala se recomienda utilizar valores de entre 2 y 5.

3.3. Implementación Cuántica: Algoritmo QWord2Vec

En la sección anterior se describió en detalle el algoritmo Word2Vec clásico y su variante Skip-gram, que emplea redes neuronales superficiales para aprender representaciones vectoriales de palabras a partir de grandes corpus de texto. En esta sección se presenta *QWord2Vec*, una adaptación cuántica de dicho modelo propuesta por Ohno [33], cuyo objetivo es explorar si el uso de circuitos cuánticos paramétricos puede ofrecer ventajas en la calidad de las representaciones vectoriales de palabras.

En esta sección se explorarán la arquitectura del circuito cuántico, la función de coste empleada para su optimización y la estrategia híbrida clásico-cuántica utilizada durante el entrenamiento.

3.3.1. Adaptación del algoritmo al entorno cuántico

El circuito cuántico de *QWord2Vec* sigue la misma estructura de Word2Vec, compuesta por una parte de **codificación** y una parte de **decodificación**. Está formado por puertas de rotación de Pauli (unitarias parametrizadas) y puertas de Pauli-X controladas para introducir entrelazamiento, organizadas en una estructura de capas con profundidad de circuito ajustable. Dado un vector *one-hot* como entrada para una palabra y un vector de salida que representa su contexto [33].

3.3.2. Diseño del Circuito Cuántico Parametrizado

Como se indicó con anterioridad, la arquitectura de *QWord2Vec* mantiene una estructura análoga a la del algoritmo clásico, dividiéndose en una fase de codificación y otra de decodificación. Esta similitud estructural se ilustra en la Figura 3.14.

En la imagen anterior, se aprecia como hay dos matrices parametrizadas, $U(\theta_u)$ y $V(\theta_v)$, junto a una matriz unitaria de entrelazamiento $U(\text{enta})$. En este sistema, n denota el número total de qubits, mientras que n_e indica el número de qubits destinados específicamente a la representación de los *embeddings*, debiendo cumplirse la restricción $1 \leq n_e \leq n$.

La entrada al circuito viene dada por el estado cuántico $|k\rangle$, el cual representa a una palabra codificada mediante un vector *one-hot* en Word2Vec




Figura 3.14: Estructura de QWord2Vec. Fuente: [33].

donde $0 \leq k \leq 2^n - 1$. A partir de este estado inicial, el sistema evoluciona hacia un estado de salida $|\psi\rangle$. Parecido al mapeo directo que realiza Word2Vec, el mapeo que hay entre $|k\rangle$ y $|\psi\rangle$ lo realizan los bloques U y V .

Los estados cuánticos de salida resultantes codifican la información correspondiente al contexto de la palabra de entrada, cuya extracción se lleva a cabo realizando mediciones en la base computacional (observable Pauli Z).

El modelo $U(\theta_u)$ y $V(\theta_v)$ utilizan las matrices unitarias parametrizadas y las matrices unitarias (U_{enta}) para proporcionar el entrelazamiento cuántico de la siguiente manera:

$$U(\theta) = \prod_{l=1}^L U_{\text{enta}} R_Z\left(\theta_z^{L-l+1}\right)^{\otimes n} R_Y\left(\theta_y^{L-l+1}\right)^{\otimes n} R_X\left(\theta_x^{L-l+1}\right)^{\otimes n};$$

donde L representa la longitud del circuito cuántico. Por simplicidad, se asumirá que tanto $U(\theta_u)$ y $V(\theta_v)$ poseen la misma profundidad, a menos que se indique explícitamente lo contrario.

Para implementar U_{enta} , se ha usado puertas controladas Pauli X (CNOT), siguiendo una configuración de circuito por bloques [45]. Esta disposición favorece notablemente la expresividad del circuito y maximiza su capacidad para generar entrelazamiento. La Figura 3.15 muestra visualmente la estructura del circuito resultante al combinar las rotaciones de Pauli con el bloque de entrelazamiento descrito.

El uso combinado de las tres puertas de rotación (R_X, R_Y, R_Z) permite que los estados cuánticos que representan a las distintas palabras alcancen una mayor dispersión en el espacio de Hilbert, superando las limitaciones de representatividad que se obtendrían empleando una sola matriz de rotación, tal y como se observa en la Figura 3.16.




Figura 3.15: Circuito cuántico parametrizado de QWord2Vec con puertas de rotación de Pauli (R_X , R_Y , R_Z) y entrelazamiento con configuración por bloques mediante puertas CNOT.

Estimación de la longitud del circuito

Con el fin de acotar el espacio de búsqueda durante el ajuste de hiperparámetros, se emplea la fórmula heurística propuesta en [33] para estimar la profundidad L del circuito cuántico:

$$L = \left\lceil \frac{\#data}{3(n + n_e)A_{th}} p(n, n_e) \right\rceil ;$$

donde los términos que intervienen en la expresión son:

- $\#data$: número de pares de entrenamiento disponibles.
- n : número total de qubits del sistema.




Figura 3.16: Representación de las palabras sobre la esfera de Bloch según las puertas de rotación empleadas en $U(\theta_u)$: (a) usando únicamente R_Y , y (b) usando R_X , R_Y y R_Z combinadas. Los puntos coloreados corresponden a las palabras y el número total de puntos es 32. El uso de las tres puertas de rotación de Pauli permite una mayor dispersión de las representaciones a lo largo del espacio de Hilbert. Fuente: [33].

- n_e : número de qubits de embeddings.
- A_{th} : umbral de tolerancia determinado de forma empírica.
- $p(n, n_e) \in [0, 0.5]$: probabilidad de error en función de n y n_e .

La expresión determina la profundidad mínima necesaria para que la cantidad promedio de datos por parámetro no supere el umbral A_{th} . Dado que cada capa aporta $3(n + n_e)$ parámetros entrenables (un parámetro entrenable por cada matriz de rotación de Pauli), la fórmula divide la carga total de entrenamiento entre dicha capacidad ponderada por el umbral. La función techo $\lceil \cdot \rceil$ garantiza que L tome un valor entero.

La probabilidad de error $p(n, n_e)$ se obtiene a partir de la siguiente inecuación, la cual relaciona la probabilidad de error entre n y n_e :

$$n_e \geq (1 - H(p)) \cdot 2^n;$$

donde $H(p)$ es la función de entropía binaria, representada en la Figura 3.17.

3.3.3. Definición de la función de evaluación y pérdida usadas

A continuación se procederá a explicar cuales han sido las funciones de evaluación y de pérdidas que han sido utilizadas para entrenar a este modelo,




Figura 3.17: Entropía binaria $H(p)$, donde p denota la probabilidad de error empleada en este estudio. Fuente: [33].

ya que difieren completamente de la aproximación clásica seguida.

Evaluación de los datos de embeddings

Para evaluar la calidad de los *embeddings* generados por QWord2Vec se emplea el coeficiente de correlación de Pearson, calculado a partir de las distancias entre los vectores producidos por ambos modelos: Word2Vec y QWord2Vec.

Una vez completado el entrenamiento, se realiza una medición sobre los qubits destinados a los *embeddings*, obteniendo así los vectores clásicos correspondientes a cada palabra. A partir de estos vectores se construye un *vector distancia* cuyas componentes son las distancias euclídeas entre los vectores de *embeddings* de todas las palabras del vocabulario. Este proceso se aplica tanto al modelo clásico como al cuántico, tomando el vector distancia de Word2Vec como referencia de comparación (*ground truth*).

El motivo por el que no se utiliza únicamente la entropía cruzada como métrica de evaluación reside en que los circuitos cuánticos con un elevado número de parámetros tienden a reducir su valor. Por ello, se añade el coeficiente de correlación de Pearson sobre los vectores distancia ya que constituye una métrica más adecuada y robusta para valorar la capacidad del modelo. En la siguiente subsección se describe en detalle la función de pérdida empleada durante el entrenamiento del circuito.

Función de pérdida

La función de pérdida diseñada para el modelo combina dos métricas. En primer lugar, emplea la *entropía cruzada*, una métrica que evalúa el grado de acierto de las predicciones de un modelo frente a la realidad. De forma intuitiva, mide la diferencia entre dos distribuciones de probabilidad: la real

(los datos objetivo) y la estimada por el modelo. Su propósito es penalizar los errores, de modo que cuanto más se alejen las predicciones de la etiqueta real, mayor será el valor de la pérdida. En el contexto de QWord2Vec, la entropía cruzada cuantifica el error entre las probabilidades generadas por el circuito cuántico y las etiquetas de entrenamiento que dictan el contexto correcto de cada palabra.

A este componente clásico poseen también un segundo término basado en el coeficiente de correlación de Pearson, el cual actúa como mecanismo para garantizar la fidelidad de las representaciones espaciales. De este modo, la función de pérdida global se expresa de la siguiente manera:

$$\mathcal{L} = \mathcal{L}_{\text{CE}} - C \cdot \rho(D, Y)$$

donde $\mathcal{L}_{\text{CE}}$ representa la pérdida por entropía cruzada y $C > 0$ es un parámetro de balanceo. Por su parte, $\rho(D, Y)$ denota el coeficiente de correlación de Pearson calculado entre el vector distancia de los *embeddings* generados por QWord2Vec (D) y el vector de etiquetas de entrenamiento (Y). Las representaciones de los *embeddings* se actualizan en cada iteración, mientras que el vector Y se obtiene de la siguiente forma:

dada una palabra objetivo del corpus, se asigna un valor de 0.5 a las dos palabras inmediatamente adyacentes a la palabra de referencia, estableciendo a cero el resto de las posiciones del vector de etiquetas de tamaño $N = 2^n$. De este modo, el vector resultante suma 1 y puede interpretarse como una distribución de probabilidad uniforme sobre los dos contextos posibles de cada palabra objetivo.

Para un vector de tamaño N correspondiente a $|k\rangle$

3.3.4. Estrategia de optimización

El algoritmo de optimización empleado en QWord2Vec es QN-SPSA, propuesto por Gacon et al. [14]. En cada paso de optimización se requiere únicamente 2 ejecuciones del circuito cuántico para estimar el gradiente y otras 4 para aproximar el tensor métrico de Fubini-Study, con un coste independiente del número de parámetros del circuito. Esta capacidad de escalado lo convierte en un candidato especialmente adecuado para tareas de optimización en dispositivos NISQ.

Para entender el funcionamiento de QN-SPSA, es necesario introducir previamente los algoritmos en los que se basa [11].

Funcionamiento del algoritmo

Los optimizadores empleados en CVCs operan bajo el mismo principio que los utilizados en ML clásico: en cada iteración estiman el gradiente de la función de coste y, a partir de este, actualizan los parámetros del modelo con el objetivo de minimizar dicha función.

El punto de partida es el Gradient Descent (GD), cuya regla de actualización de parámetros es:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \eta \nabla f(\mathbf{x}^{(t)});$$

donde f es la función de pérdida, $\mathbf{x}$ el vector de parámetros, η la tasa de aprendizaje y el superíndice t la iteración actual. El gradiente ∇f se calcula dimensión a dimensión, lo que implica $\mathcal{O}(d)$ mediciones cuánticas, siendo d el número de parámetros entrenables. Dado el elevado coste de las mediciones en un circuito cuántico, el GD resulta inviable para circuitos con un número alto de parámetros así como un gran número de iteraciones para la optimización.

Para resolver este problema de escalado, surgió el optimizador SPSA [56]. En lugar de calcular el gradiente componente a componente, SPSA selecciona una dirección aleatoria $\mathbf{h} \in U(\{-1, 1\}^d)$, donde $U(\{-1, 1\}^d)$ es una distribución uniforme discreta de d dimensiones, y estima el gradiente proyectado mediante una aproximación de diferencias finitas con perturbación ϵ :

$$\nabla_{\mathbf{h}} f(\mathbf{x}) \equiv \mathbf{h} \cdot \nabla f(\mathbf{x}) \simeq \frac{1}{2\epsilon} (f(\mathbf{x} + \epsilon \mathbf{h}) - f(\mathbf{x} - \epsilon \mathbf{h})).$$

A partir de esta expresión se construye el estimador estocástico del gradiente:

$$\widehat{\nabla} f(\mathbf{x}, \mathbf{h})_{\text{SPSA}} = \nabla_{\mathbf{h}} f(\mathbf{x}) \mathbf{h},$$

con el que la regla de actualización de parámetros queda:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \eta \widehat{\nabla} f(\mathbf{x}^{(t)}, \mathbf{h}^{(t)})_{\text{SPSA}},$$

donde $\mathbf{h}^{(t)}$ se muestrea en cada iteración. Al tratarse de una aproximación estocástica, el gradiente estimado no es exacto, pero se ha demostrado que el algoritmo converge de forma efectiva cuando se realizan suficientes iteraciones de optimización.

Sin embargo, SPSA hereda del GD el problema de operar en el espacio euclídeo de los parámetros, lo que hace que el resultado de la optimización dependa de la parametrización elegida. Para eliminar esta dependencia, Amari (1998) propuso el algoritmo clásico *Natural Gradient Descent*, que reformula el problema de optimización en términos de distribuciones de probabilidad sobre las posibles salidas del modelo. De este modo, cada paso de optimización resulta invariante frente a reparametrizaciones, ya que se realiza en el espacio de distribuciones en lugar del espacio de parámetros. Su regla de actualización incorpora la matriz de información de Fisher F como tensor métrico:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \eta F^{-1} \nabla f(\mathbf{x}^{(t)}).$$

La matriz de información de Fisher actúa como un tensor métrico que transforma los pasos de descenso realizados en el espacio euclídeo de los parámetros en pasos de descenso en el espacio de distribuciones de probabilidad.

La versión cuántica de este algoritmo, Quantum Natural Gradient Descent (QNG) [48], traslada este mismo principio al espacio de estados cuánticos. En dicho espacio, el tensor métrico invariante es el **tensor de Fubini-Study** $\mathbf{g}$, de dimensiones $d \times d$, definido como:

$$g_{ij}(\mathbf{x}) = -\frac{1}{2} \frac{\partial}{\partial \mathbf{x}_i} \frac{\partial}{\partial \mathbf{x}_j} F(\mathbf{x}', \mathbf{x}) \Big|_{\mathbf{x}'=\mathbf{x}},$$

donde $F(\mathbf{x}', \mathbf{x}) = |\langle \phi(\mathbf{x}') | \phi(\mathbf{x}) \rangle|^2$ y $\phi(\mathbf{x})$ es el circuito ansatz parametrizado con entrada $\mathbf{x}$. La regla de actualización de QNG es:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \eta \mathbf{g}^{-1}(\mathbf{x}^{(t)}) \nabla f(\mathbf{x}^{(t)}).$$

El uso del tensor $\mathbf{g}$ permite una convergencia más rápida y hacia mejores mínimos que el GD. No obstante, su cálculo requiere un gran número de mediciones cuánticas, lo que lo hace igualmente inescalable para circuitos de gran tamaño y con gran número de iteraciones para optimizarlos.

QN-SPSA surge precisamente como solución a esta limitación, combinando las ventajas de SPSA y QNG. Estima de forma estocástica tanto el gradiente como el tensor de Fubini-Study, manteniendo un coste constante independiente de d . El gradiente se estima con el mismo procedimiento que en SPSA, mientras que el tensor se aproxima mediante un estimador de segundo orden con dos perturbaciones estocásticas adicionales:

$$\widehat{\mathbf{g}}(\mathbf{x}, \mathbf{h}_1, \mathbf{h}_2)_{\text{SPSA}} = \frac{\delta F}{8\epsilon^2} \left(\mathbf{h}_1 \mathbf{h}_2^\top + \mathbf{h}_2 \mathbf{h}_1^\top \right),$$

donde

$$\delta F = F(\mathbf{x}, \mathbf{x} + \epsilon \mathbf{h}_1 + \epsilon \mathbf{h}_2) - F(\mathbf{x}, \mathbf{x} + \epsilon \mathbf{h}_1) - F(\mathbf{x}, \mathbf{x} - \epsilon \mathbf{h}_1 + \epsilon \mathbf{h}_2) + F(\mathbf{x}, \mathbf{x} - \epsilon \mathbf{h}_1),$$

y $\mathbf{h}_1, \mathbf{h}_2 \in U(\{-1, 1\}^d)$ son dos direcciones de perturbación muestreadas aleatoriamente. La regla de actualización de parámetros resultante es:

$$\mathbf{x}^{(t+1)} = \mathbf{x}^{(t)} - \eta \widehat{\mathbf{g}}^{-1}(\mathbf{x}^{(t)}, \mathbf{h}_1^{(t)}, \mathbf{h}_2^{(t)})_{\text{SPSA}} \widehat{\nabla} f(\mathbf{x}^{(t)}, \mathbf{h}^{(t)})_{\text{SPSA}}.$$

Cada paso de optimización t requiere tres direcciones de perturbación $\mathbf{h}^{(t)}, \mathbf{h}_1^{(t)}, \mathbf{h}_2^{(t)}$, lo que se traduce en 2 evaluaciones del circuito para el gradiente y 4 para el tensor, con una complejidad total de $\mathcal{O}(1)$ respecto al número de parámetros. Esta propiedad lo convierte en el optimizador idóneo para su uso en dispositivos NISQ. La Figura 3.18 muestra una comparativa del comportamiento de los distintos algoritmos de optimización descritos.




Figura 3.18: Comparativa de los algoritmos de optimización GD, SPSA, QNG y QN-SPSA en términos de convergencia y coste computacional. Fuente: [11].

Como se puede apreciar, en este caso sale que el que mejor resultados tiene es QNG. Sin embargo aquí no se está contemplando el tiempo de ejecución, que como se comentó, este optimizador es menos eficiente y no escala bien (aquí se tienen pocas iteraciones). Con esto se demuestra como el QN-SPSA es el que mejor resultado ofrece de manera equilibrada, teniendo una pérdida (loss) baja así como un tiempo de ejecución también menor y siendo una opción buena en cuanto a la escalabilidad.

Capítulo 4

Experimentación y Análisis de Resultados

Una vez descritos los fundamentos teóricos de Word2Vec y QWord2Vec, este capítulo recoge el proceso de experimentación llevado a cabo para comparar ambos modelos.

El objetivo principal de esta experimentación es evaluar si los *embeddings* generados por QWord2Vec son capaces de preservar relaciones semánticas entre palabras de forma comparable a los producidos por Word2Vec. Se explicará el corpus y la configuración de los hiperparámetros, para luego pasar al análisis de la función de pérdida durante el entrenamiento y terminar con la evaluación de la calidad de los *embeddings* con distintas métricas usadas. Asimismo, se incluye un análisis comparativo de los tiempos de ejecución de ambos modelos, dado que el coste computacional es uno de los factores críticos en el contexto de la computación cuántica simulada.

La primera experimentación se realizará con el dataset usado en el artículo [33]. Luego habrá una segunda experimentación con un dataset más uniforme y con mayores instancias de entrenamiento partiendo del primer dataset utilizado para analizar así cómo mejora los modelos al aumentar un poco el número de instancias de entrenamiento.

4.1. Metodología experimental

A continuación se describe los pasos previos necesarios para llevar a cabo la experimentación. En primer lugar, se presenta el corpus empleado para el entrenamiento de ambos modelos, junto con el proceso de preprocesamiento aplicado en cada caso. al finalizar la explicación, se detallarán las herramientas y el entorno de ejecución utilizados, aspecto especialmente relevante en el caso de QWord2Vec, dado que la simulación clásica de circuitos cuánticos impone restricciones significativas sobre el tamaño del experimento realizable.

4.1.1. Dataset y preprocesamiento

Como se comentó anteriormente, la simulación clásica de circuitos cuánticos impone restricciones severas sobre el tamaño del experimento. A diferencia de Word2Vec clásico, que habitualmente se entrena con corpus de millones de frases y vocabularios de cientos de miles de palabras. El coste computacional de simular un circuito cuántico crece exponencialmente con el número de qubits, lo que hace inviable trabajar con corpus de gran escala en un equipo personal que es con el que se ha trabajado.

Por este motivo, la primera prueba de experimentación ha sido adoptando el mismo corpus empleado en el trabajo de referencia [33], el cual fue tomado originalmente de una fuente web la cual ofrecía corpus pequeños para realizar evaluaciones de modelos de este estilo. El corpus consta de 13 frases en inglés con un vocabulario de 13 palabras únicas. Las frases utilizadas son las siguientes:

```
i like dog    i like cat    i like animal    dog cat animal
apple cat dog like    dog fish milk like    dog cat eyes
like
i like apple    apple i hate    apple i movie
book music like    cat dog hate    cat dog like
```

Las frases tienen una longitud de entre 3 y 4 palabras, lo que condiciona el tamaño de la ventana de contexto haciendo que sea pequeña. Desde el punto de vista de la distribución léxica, el corpus presenta un desequilibrio: las cuatro palabras más frecuentes (*like*, *dog*, *cat* e *i*) concentran el 67% de los tokens totales, mientras que seis palabras del vocabulario aparecen una única vez. Este desequilibrio tiende a introducir distorsiones en las relaciones semánticas aprendidas por el modelo, y es una limitación que se asume de forma consciente.

No obstante, el uso de este corpus está justificado por tres razones. En primer lugar, permite reproducir directamente las condiciones experimentales del paper de referencia, facilitando la comparación de resultados durante el desarrollo e implementación de variaciones que se han realizado. En segundo lugar, el objetivo del estudio no es obtener un modelo de procesamiento del lenguaje natural de calidad, sino evaluar si QWord2Vec es capaz de preservar las relaciones semánticas que aprende Word2Vec. Para este fin, un corpus pequeño y controlado es suficiente. Por último, el tamaño reducido del vocabulario permite inspeccionar e interpretar los *embeddings* obtenidos de forma directa, verificando manualmente que las relaciones semánticas resultantes son coherentes con el contenido del corpus.

En lo relativo al preprocesamiento del texto, no ha sido necesario aplicar ninguna técnica adicional sobre el conjunto de datos original. Esto se debe a que el corpus de experimentación es un conjunto ya preprocesado. Todas sus oraciones están escritas en minúsculas, no tienen signos de puntuación o

caracteres especiales, y sus términos están delimitados por espacios simples. Por consiguiente, las etapas clásicas del procesamiento del lenguaje natural resultan redundantes, permitiendo que la separación básica por espacios genere directamente los *tokens* esperados para la etapa de entrenamiento.

4.1.2. Entorno de ejecución y herramientas

Todos los experimentos se han llevado a cabo sobre un ordenador personal con sistema operativo Ubuntu, cuya compatibilidad con las librerías empleadas y su integración con el hardware disponible lo hacen especialmente adecuado para este tipo de desarrollo. Las características del hardware relevantes para el rendimiento son las siguientes:

- **Procesador:** Intel Core i7-13700F (30 MB de caché, frecuencia máxima superior a 5,2 GHz).
- **Memoria RAM:** 32 GB DDR4 a 3600 MHz.
- **Tarjeta gráfica:** MSI GeForce RTX 4070 con 12 GB de memoria GDDR6X.

En cuanto al software, las herramientas y librerías principales utilizadas en el desarrollo son:

- **Python 3.10.12:** lenguaje de programación base del proyecto en el que se han desarrollado las implementaciones de ambos algoritmos.
- **Gensim 4.4.0:** empleada para el modelo clásico. Esta librería incluye tanto la arquitectura de Word2Vec como la función de optimización *Negative Sampling*, desarrollada siguiendo las especificaciones originales de Google.
- **Qiskit 1.4.5:** utilizada para la versión cuántica. Proporciona las herramientas necesarias para la construcción del circuito parametrizado, la aplicación del optimizador descrito en el capítulo anterior, así como utilidades para la medición y transpilación del circuito.
- **Qiskit Aer 0.17.2:** *backend* de simulación cuántica sobre hardware clásico.

Respecto a la elección del simulador cuántico, *Qiskit* ofrece tres opciones: *AerSimulator*, *StatevectorSimulator* y *QasmSimulator*. Los dos últimos se encuentran en proceso de deprecación, dado que *AerSimulator* los unifica y supera en capacidades siendo el que más soporte y desarrollo recibe en la actualidad. Por este motivo, se ha optado por *AerSimulator* como backend de simulación para la ejecución de QWord2Vec.

4.1.3. Configuración de hiperparámetros

Tanto el modelo clásico como el cuántico presentan una serie de hiperparámetros que deben ajustarse para obtener el mejor rendimiento posible, como ocurre en cualquier problema de ML. Para su configuración se ha empleado la técnica de búsqueda exhaustiva *Grid Search* [53], implementada manualmente en ambos casos al no disponer de una implementación genérica compatible con los modelos utilizados.

La estrategia seguida ha consistido en identificar, a partir de la literatura y de experiencias previas en problemas similares que han comentado distintas personas en foros, un conjunto de valores de referencia para cada hiperparámetro. A partir de estos valores, se han definido rangos de búsqueda que incluyen el valor de referencia junto con variaciones por encima y por debajo, con el objetivo de ajustar cada parámetro al corpus y al problema concreto. Dado que ambos modelos emplean funciones de pérdida y algoritmos de optimización distintos, cada uno dispone de su propio conjunto de hiperparámetros a explorar.

4.1.4. Hiperparámetros de Word2Vec

Los hiperparámetros de Word2Vec pueden agruparse en tres categorías ya que están los propios de la arquitectura Skip-Gram, los relacionados con Negative Sampling y el correspondiente al optimizador.

En cuanto a los hiperparámetros de **Skip-Gram**, los dos parámetros ajustados son *vector_size* y *window*. El primero determina la dimensionalidad de los vectores de *embedding*, es decir, el número de características con el que se representa cada palabra. Su elección depende del tamaño del vocabulario, la riqueza semántica del corpus y los recursos computacionales disponibles. Dado que el vocabulario es de únicamente 13 palabras, no se requiere una representación de alta dimensionalidad para capturar las relaciones semánticas presentes. Por ello, se exploraron con solo dos valores que son el $\{2, 4\}$. El valor seleccionado por el *Grid Search* fue *vector_size* = 2, lo cual resulta coherente con el reducido tamaño del vocabulario y presenta la ventaja adicional de permitir visualizar directamente los *embeddings* en el plano y realizar una validación manual sin necesidad de aplicar técnicas de reducción de dimensionalidad como PCA.

El segundo parámetro, *window*, define la distancia máxima entre la palabra central y las palabras de contexto consideradas durante el entrenamiento, tal y como se ilustra en la Figura 4.1. Los valores explorados fueron $\{1, 2\}$, teniendo en cuenta que las frases del corpus tienen entre 3 y 4 palabras. El valor seleccionado fue *window* = 2, la palabra central puede relacionarse con todas las demás en una frase de 4 palabras, mientras que si se hubiera elegido el tamaño 1, solo se consideraría la palabra adyacente.

Respecto a los hiperparámetros de **Negative Sampling**, los paráme-




Figura 4.1: Ilustración del parámetro window en Skip-Gram: distancia máxima desde la palabra central hasta las palabras de contexto consideradas. Fuente: [2].

tros explorados son *negative* y *ns_exponent*. El primero indica el número de muestras negativas que se generan por cada par positivo durante el entrenamiento. El artículo original publicado por Google [31] recomendó valores entre 5 y 20 (siendo 20 para corpus de gran escala). Dado que el corpus empleado cuenta únicamente con 13 palabras únicas, se optó por explorar valores ligeramente inferiores al valor mínimo que recomendaba el artículo de Google. Estos valores fueron el $\{2, 3\}$ siendo seleccionado *negative* = 2.

El parámetro *ns_exponent* controla la distribución de probabilidad con la que se seleccionan las palabras negativas. Un valor de 1 desfavorece a las palabras poco frecuentes respecto a una distribución puramente proporcional a las frecuencias, mientras que un valor de 0,0 trata todas las palabras con igual probabilidad. El artículo original de Word2Vec [31] estableció 0.75 como valor fijo. Sin embargo, un estudio posterior [9] argumentó que este parámetro debería adaptarse al problema concreto. Dado el notable desequilibrio léxico del corpus utilizado, se exploraron los valores $\{0.0, 0.2\}$. El valor seleccionado fue *ns_exponent* = 0.0, lo que implica que todas las palabras tienen igual probabilidad de ser seleccionadas como muestras negativas, compensando en parte el desequilibrio de frecuencias del corpus.

Por último, los hiperparámetros relacionados con el **optimizador** son α y *epochs*. El primero establece la tasa de aprendizaje inicial del modelo, y el segundo el número total de épocas de entrenamiento. Aunque a primera vista *epochs* podría considerarse un parámetro independiente del optimizador, en *Gensim* ambos están directamente acoplados. Esto se debe a que la librería implementa internamente un decaimiento lineal de la tasa de aprendizaje desde α hasta el valor *min_alpha* (0.0001 por defecto), de modo que el aprendizaje llega a su valor mínimo exactamente en la última época planificada. En consecuencia, el valor efectivo de la tasa de aprendizaje en cada paso depende simultáneamente de ambos parámetros, y por ello se ha decidido ajustarse de forma conjunta dentro del mismo *Grid Search*. Para α se exploraron valores en escala lineal en el intervalo $[0.35, 0.75]$, y para *epochs* los valores $\{300, 400, 500\}$. La combinación seleccionada fue $\alpha = 0.59$ y *epochs* = 500, valores relativamente elevados que se justifican por las ca-

racterísticas del corpus. Con tan pocos pares de entrenamiento, el modelo necesita pasos de gradiente agresivos para escapar de mínimos locales antes de que el decaimiento lineal lleve a α a valores muy bajos y por tanto le cueste salir de los mínimos locales. Con corpus de mayor escala estos valores producirían oscilaciones inestables, pero en este escenario controlado el *Grid Search* confirma empíricamente que maximizan la calidad semántica de los *embeddings*.

4.1.5. Hiperparámetros de QWord2Vec

Los hiperparámetros del modelo cuántico pueden agruparse en tres categorías que son: los propios del circuito, los relacionados con SPSA y los correspondientes al QNG. En la implementación utilizada, la clase que implementa el algoritmo QN-SPSA integra los tres bloques en uno solo.

En cuanto a los hiperparámetros del **circuito**, los dos parámetros ajustados son el número máximo de iteraciones y el número de muestras por simulación *shots*. Para el primero, se tuvo en cuenta que los circuitos variacionales cuánticos suelen necesitar muchas iteraciones para converger. El trabajo original de [33] empleó hasta 20.000 iteraciones. Dado que QN-SPSA está diseñado para converger en un número reducido de iteraciones, se consideró que 2500 iteraciones constituyen un límite suficientemente holgado, respaldado además por el mecanismo de *early stopping* descrito en la sección de entrenamiento. El valor del número de *shots* se fijó en 2048, un nivel elevado que reduce la varianza estadística de las distribuciones de probabilidad estimadas por el simulador y produce estimaciones más fiables de la función de pérdida.

Otro parámetro propio del circuito es el umbral A_{th} , que interviene en la fórmula heurística para estimar el número de capas L del circuito y representa la fracción máxima de datos de entrenamiento que se acepta perder. Su búsqueda se realizó en dos fases. En la primera de ellas, y teniendo en cuenta que el paper de referencia de la heurística indicaba que los mejores valores de A_{th} se situaban en el intervalo $[0.01, 0.05]$, se evaluaron valores representativos dentro de dicho rango: $\{0.02, 0.03, 0.04, 0.05\}$. Los resultados de esta fase mostraron que los valores más altos (0.04–0.05) producen circuitos con muy pocas capas ($L \leq 6$), insuficientes para capturar la geometría del espacio de *embeddings*, mientras que los valores más bajos, especialmente 0.02 y 0.03, proporcionaban los mejores resultados. A partir de aquí, se acotó el rango de búsqueda en torno a dichos candidatos, explorando en la segunda fase los valores $\{0.018, 0.021, 0.024\}$. El valor seleccionado fue $A_{th} = 0.021$ (que coincide a su vez con el mismo valor del artículo [33] aunque se usaron métodos distintos para explorarlo). Añadido a A_{th} se encuentra otra constante que es el valor $C = 2$ de la función de pérdida, este valor se ha utilizado el que indicaba el paper de referencia que mejor le fue para el corpus que se ha utilizado. Esto es porque el paper utiliza una función para calcular C en

función de A_{th} , pero el A_{th} mejor encontrado por el grid search, coincidía con el mismo A_{th} del paper.

Respecto a los hiperparámetros de **SPSA**, los parámetros ajustados son los coeficientes iniciales de la tasa de aprendizaje a y de la perturbación c . Los exponentes de decaimiento $\alpha = 0.602$ y $\gamma = 0.101$ se tomaron directamente del paper original del algoritmo SPSA [46], dado que han sido validados matemáticamente y empíricamente por el autor y no requieren ajuste al problema concreto. Por el contrario, a y c sí dependen de las características de cada problema. Para estos dos parámetros se optó por valores moderadamente pequeños, por dos razones principales. En primer lugar, el optimizador se combina con una inicialización de los pesos basada en un *educated guess*. Esta técnica consiste en lo siguiente, antes de comenzar la optimización se evalúan 10 puntos de inicio aleatorios y se selecciona aquel con menor pérdida, lo que proporciona al optimizador un punto de partida ya orientado hacia una región prometedora del espacio de parámetros, sin necesidad de un paso de aprendizaje agresivo para explorar regiones lejanas. Segundo, los valores de pérdidas de un circuito variacional cuántico sin pesos preentrenados son especialmente ruidosos en las primeras iteraciones, debido a la alta varianza de las estimaciones obtenidas por muestreo finito del simulador, de modo que valores demasiado grandes de a o c podrían generar actualizaciones de parámetros inestables que alejasen al optimizador de la región de inicio favorable.

La búsqueda de a y c se realizó también en dos fases, de forma conjunta con el resto de hiperparámetros. En la primera exploración se utilizó un espacio amplio que incluía además los hiperparámetros de QNG, con el objetivo de identificar las regiones más prometedoras para todos los parámetros simultáneamente. A partir de los mejores resultados obtenidos se realizó una segunda búsqueda más afinada con los mejores resultados obtenidos de la primera búsqueda. En esta segunda búsqueda, los valores candidatos propuestos han sido $a \in \{0.10, 0.16, 0.25\}$ y $c \in \{0.05, 0.07, 0.12\}$. Los valores seleccionados fueron $a = 0.16$ y $c = 0.07$. Adicionalmente, se activó el parámetro *blocking*, que restringe las actualizaciones del optimizador a aquellos casos en que la nueva pérdida no supere la anterior en más de una tolerancia fija, favoreciendo una convergencia más robusta.

Por último, los hiperparámetros relacionados con el **QNG** son la regularización del tensor métrico de Fubini-Study, el *hessian delay* y el *resampling*. Para su configuración se siguieron las recomendaciones disponibles en la literatura [11], que indican inicializar el tensor métrico de Fubini-Study como la matriz identidad en $g^{(0)}$. El coeficiente de regularización se ajustó teniendo en cuenta que un valor demasiado alto eliminaría la información del tensor métrico, mientras que un valor demasiado bajo provocaría su desvanecimiento en regiones próximas a un mínimo. Los valores explorados en la primera fase del grid search fueron $\{10^{-4}, 5 \cdot 10^{-4}, 3 \cdot 10^{-3}\}$, y la segunda fase afinó la búsqueda en torno al mejor candidato, con el valor seleccionado

de $1.6 \cdot 10^{-2}$. El *hessian delay* controla el número de iteraciones iniciales durante las cuales el tensor métrico no se aplica, evitando así que el ruido elevado de las primeras iteraciones distorsione la estimación del QNG. Los valores explorados incluyeron $\{200, 300, 400, 500, 700\}$, y el valor seleccionado fue 400. El *resampling* indica cuántas veces se ejecuta el cálculo del tensor métrico y se promedia el resultado, introduciendo mayor estabilidad a costa de un coste computacional adicional. Se fijó en un valor bajo (5) para mantener la viabilidad del experimento en un entorno de computación personal aunque esto supuso un aumento en el coste de computación algo considerable. Por último, dado que el corpus cuenta con 13 palabras y cada una tiene asignado un circuito con su propia codificación binaria en el espacio de Hilbert, se diseñó una estrategia de estimación rotativa del tensor métrico de Fubini-Study. En cada llamada al cálculo de la fidelidad, el circuito de referencia se selecciona de forma cíclica y uniforme a lo largo del vocabulario, de modo que el QNG recibe información geométrica de todas las palabras a lo largo del entrenamiento y no queda sesgado hacia ninguna de ellas en particular. Esta decisión de implementación fue adoptada para evitar que el tensor métrico se estimara siempre sobre el mismo circuito, lo que podría introducir un sesgo sistemático en la dirección del gradiente natural.

4.2. Entrenamiento

En esta sección se describe el proceso de entrenamiento seguido para cada modelo. Dado que Word2Vec y QWord2Vec emplean funciones de pérdida y algoritmos de optimización distintos, el análisis de cada uno se presenta de forma independiente.

4.2.1. Word2Vec

El proceso de entrenamiento de Word2Vec se basa en la función de pérdida de Negative Sampling, como se explicó con anterioridad. Sin embargo, minimizar esta función auxiliar no garantiza directamente una buena calidad semántica de los *embeddings*. Negative Sampling es un objetivo sustituto cuyo fin es entrenar al modelo para discriminar pares de palabras reales del corpus frente a pares generados aleatoriamente como ruido, no para maximizar de forma explícita la similitud entre palabras semánticamente relacionadas. En consecuencia, es posible que el modelo encuentre soluciones en las que la pérdida sea baja pero los *embeddings* no reflejen adecuadamente la estructura semántica del vocabulario. Por ello, se ha incorporado una métrica de evaluación adicional, denominada *cosine_delta*, que cuantifica directamente la coherencia semántica de los vectores obtenidos a partir de la similitud coseno sobre pares de palabras anotados manualmente.

El rol de cada componente es el siguiente. **Train loss** actúa como función de optimización, proporcionando la señal con la que el optimizador actualiza los parámetros en cada iteración. El **cosine_delta** constituye la métrica de calidad real de los *embeddings* y es la que determina cuándo el modelo se encuentra en su mejor configuración semántica. Esta distinción es importante ya que el *train loss* de Negative Sampling es una señal estocástica que puede seguir oscilando incluso cuando los *embeddings* han convergido, por lo que utilizarla para decidir el mejor punto del entrenamiento llevaría a seleccionar configuraciones subóptimas.

El **cosine_delta** se define como la diferencia de medias entre dos conjuntos de pares de palabras anotados manualmente:

$$\text{cosine_delta} = \overline{\cos}(\text{pares similares}) - \overline{\cos}(\text{pares disimilares});$$

Para construir ambos conjuntos se ha generado primero un agrupamiento (*ground truth*) de las palabras del vocabulario a partir del corpus teniendo en cuenta que los grupos fueran lo más equilibrados posible y sin que una misma palabra apareciera en distintos grupos. Estos fueron los cuatro clústeres semánticos generados:

- **animal:** *dog, cat, animal, eyes*
- **food:** *apple, fish, milk*
- **culture:** *book, music, movie*
- **sentiment:** *i, like, hate*

A partir de estos clústeres se han definido 14 pares similares (todos los pares de palabras dentro de un mismo clúster) y 10 pares disimilares (pares de palabras de clústeres distintos seleccionados manualmente). El *cosine_delta* es entonces la diferencia entre la similitud coseno media de los primeros y la de los segundos. Un valor alto indica simultáneamente cohesión interna en cada clúster y separación entre clústeres, esto es de vital importancia para considerar que los *embeddings* reflejan correctamente la estructura semántica del corpus.

Estrategia de selección del mejor modelo: La evaluación del *cosine_delta* se realiza al final de cada época y, si el valor obtenido supera el mejor registrado hasta el momento, se guarda una copia completa del modelo en disco. El entrenamiento siempre completa la totalidad de las épocas planificadas (*epochs* = 500), sin detenerse antes de tiempo, y al finalizar se recupera el *checkpoint* que registró el mejor *cosine_delta*. Esta estrategia, conocida en inglés como *Best Model Checkpointing*, se ha preferido al *Early Stopping* clásico por tres razones. En primer lugar, como se explicó en la

sección de hiperparámetros, en *Gensim* la tasa de aprendizaje decae linealmente hasta llegar a su mínimo en la última época planificada, por lo que si se interrumpe el entrenamiento prematuramente dejaría a α en valores intermedios y comprometería la reproducibilidad del modelo. En segundo lugar, el *Best Model Checkpointing* permite explorar un mayor número de configuraciones intermedias y quedarse con la mejor, mientras que el *Early Stopping* podría detener la búsqueda antes de alcanzar un mínimo posterior. Por último, al ver que solo son necesarias 500 iteraciones de entrenamiento y que el modelo es muy eficiente, no se ve comprometido en ningún momento el modelo ni se produce un desperdicio de tiempo computacional considerable el dejar ejecutarse todas las iteraciones.

Respecto a la partición de los datos, el entrenamiento se ha realizado con el 100 % del corpus, sin reservar un conjunto de validación o prueba. Esta decisión fue tomada ya que uno de los objetivos del experimento de la versión clásica no es evaluar la capacidad de generalización del modelo a palabras nuevas, sino obtener *embeddings* de referencia para todas las palabras del vocabulario. Dado que Word2Vec solo genera un vector para una palabra si la ha observado durante el entrenamiento, excluir un subconjunto de frases implicaría que algunas palabras del vocabulario carecerían de *embedding*, dificultando la comparación con QWord2Vec, que requiere los vectores de referencia de todo el corpus.

El modelo se entrena desde cero utilizando los mejores hiperparámetros encontrados en el *Grid Search*. Una vez completadas las 500 épocas, se carga el mejor modelo con el mejor *cosine_delta* obtenido y se exportan sus *embeddings* a un fichero de texto plano para su uso como referencia de comparación en la implementación cuántica.

La evolución del *cosine_delta* y del *train loss* a lo largo del entrenamiento puede observarse en la Figura 4.2.

En la gráfica se ve con claridad por qué el *train loss* no es una métrica adecuada para seleccionar el mejor modelo. En primer lugar, en varias épocas el valor se puede ver como es cero, lo cual no refleja una pérdida real nula sino un problema conocido de la implementación de la librería. La librería está implementada en el lenguaje de programación C, al importarlo en Python, se ejecutan sin el *Global Interpreter Lock* que este tiene para así acelerar el entrenamiento, y la variable que la acumula se actualiza de forma concurrente desde distintos hilos de trabajo. Esta concurrencia introduce condiciones de carrera y pérdidas de actualizaciones ya que no ha sido bien gestionado, de manera que en algunas épocas el contador no llega a registrar las pérdidas de la iteración antes de que el *callback* de *Gensim* consulte y reinicie su valor, devolviendo entonces un cero. Este comportamiento se documenta en una *pull request* abierta hace varios años en el repositorio oficial de la librería que todavía no ha sido integrada [4]. Por este motivo, el código del proyecto aplica además un cálculo manual del incremento del *loss* entre épocas, que es el valor que aparece representado en la figura. En segundo




Figura 4.2: Evolución del *cosine_delta* (eje izquierdo, naranja) y del *train loss* (eje derecho, azul) a lo largo del entrenamiento de *Word2Vec*. La línea vertical verde indica la época en la que se registró el mejor *checkpoint*.

lugar, incluso descartando los ceros, la pérdida presenta picos puntuales que superan los 6 y en ocasiones llegan a 20, oscilaciones inherentes al carácter estocástico de *Negative Sampling* a la hora de seleccionar los pares negativos y que se tiene solo un corpus de 13 palabras.

Frente a esta señal poco fiable, el *cosine_delta* oscila mucho al inicio debido a las altas tasas de aprendizaje, luego a partir de la época 220 aproximadamente sigue una trayectoria ascendente que culmina con su mejor valor en torno a la época 400, donde alcanza un *cosine_delta* de 0.8927. Tras este punto, el modelo entra en una fase de degradación quedándose en un valle que evidencia el comienzo del sobreajuste sobre un corpus tan reducido. El mecanismo de *Best Model Checkpointing* contiene el mejor modelo encontrado en la época 399.

4.2.2. QWord2Vec

El proceso de entrenamiento de *QWord2Vec* se basa en la función de pérdida personalizada descrita en el capítulo anterior, que combina la entropía cruzada con el coeficiente de correlación de Pearson. Sin embargo, esta función de pérdida no indica de forma directa si el modelo está prediciendo correctamente los contextos esperados para cada palabra. Por ello, al igual que en *Word2Vec*, se ha incorporado una métrica de evaluación adicional

que permite cuantificar la calidad del modelo de forma más interpretable el *error rate*, que es el mismo que se utiliza en el artículo de referencia [33].

Mientras que la **función de pérdida** actúa como señal de optimización, guiando al algoritmo QN-SPSA en la actualización de los parámetros del circuito en cada iteración. El **error rate** constituye la métrica de calidad real y es la que determina el criterio de parada. La función de pérdida puede oscilar o descender lentamente incluso cuando los pesos ya han alcanzado una configuración adecuada, por lo que usarla directamente como criterio de parada podría llevar a detener el entrenamiento de forma prematura o excesivamente tardía.

Aquí se ha utilizado la técnica de *Early Stopping* ya que se ejecuta un mayor número de épocas y cada iteración requiere mucho tiempo de ejecución. El *Early Stopping* monitoriza el *error rate* cada 10 iteraciones y detiene el entrenamiento si no se supera el mejor valor previo en al menos un delta mínimo de 0.005 durante 10 comprobaciones consecutivas (paciencia = 10). La frecuencia de evaluación se ha fijado en 100 iteraciones, en lugar de evaluar en cada paso, con el objetivo de reducir el coste computacional. Esto se debe a que cada evaluación requiere ejecutar una simulación completa del circuito sobre todos los datos de entrenamiento, que es precisamente el cuello de botella del sistema al utilizar simuladores cuánticos con ordenadores convencionales. En el momento en que se activa la parada, se recupera el modelo correspondientes al mejor *error rate* registrado.

Respecto a la partición de los datos, el entrenamiento se ha realizado igualmente con el 100 % del corpus, por las mismas razones explicadas en la sección de Word2Vec. Es necesario disponer de un *embedding* para cada palabra del vocabulario con el fin de poder realizar la comparación entre ambos modelos.

En cuanto al flujo de entrenamiento, antes de comenzar la optimización se lleva a cabo una inicialización de los parámetros del circuito ya que se está entrenando desde cero. El procedimiento es el siguiente, se generan 10 puntos de inicio aleatorios y se evalúa la función de pérdida en cada uno de ellos, seleccionando aquel que presenta el valor más bajo como punto de partida para el optimizador. Esta estrategia reduce el riesgo de quedar atrapado en mínimos locales desde el inicio del entrenamiento obteniendo una ventaja en el inicio del entrenamiento.

A continuación, se definen dos funciones generadoras, en cada iteración actualizan la tasa de aprendizaje y la magnitud de la perturbación del algoritmo QN-SPSA siguiendo el esquema de decaimiento recomendado por los autores del algoritmo SPSA original. Adicionalmente, se ha activado el parámetro *blocking*, que restringe las actualizaciones de pesos a aquellos casos en que la nueva pérdida calculada no supere en más de el doble de desviación estandar del valor actual. Este mecanismo fuerza una convergencia más robusta, permitiendo al optimizador escapar de mínimos locales sin aceptar degradaciones excesivas de la función de pérdida.

Una vez finalizado el entrenamiento, se calcula el *error rate* final con los mejores pesos encontrados y se registra la evolución de la pérdida a lo largo de todas las iteraciones. La Figura 4.3 muestra dicha evolución junto con los valores de *error rate* y de pérdidas evaluados en cada comprobación.



Figura 4.3: Evolución de la función de pérdida (eje izquierdo, azul) y del *error rate* (eje derecho, naranja) a lo largo del entrenamiento de QWord2Vec. La línea discontinua indica el mejor *error rate* registrado, punto en el que se activa el *Early Stopping*.

La figura permite extraer diversas conclusiones sobre el comportamiento del algoritmo durante el entrenamiento.

Comportamiento de la función de pérdida: Tal y como se describió en su definición, la función de pérdida está controlada por el parámetro C , que actúa como factor de equilibrio sobre la entropía cruzada calculada entre los *embeddings* de QWord2Vec y las etiquetas de entrenamiento. Dichas etiquetas toman un valor de 0.5 en las dos posiciones correspondientes a los dos contextos más frecuentes (*top-2*) de la palabra objetivo en el corpus, y 0 en el resto. En consecuencia, la función de pérdida puede tomar valores negativos. Este hecho indica que el modelo está adquiriendo una representación adecuada en el espacio de *embeddings*. A partir de la iteración 210 aproximadamente, la pérdida comienza a situarse de forma consistente por debajo de cero, confirmando que el optimizador está tomando una mayor importancia los valores de la correlación cruzada entre *embeddings* y las etiquetas de entrenamiento.

Evolución del *error rate*: La métrica de *error rate* muestra una tendencia decreciente paralela a la de la función de pérdida a lo largo del entrenamiento, lo que refuerza la coherencia entre ambas métricas y confirma que son complementarias y consistentes con la calidad del aprendizaje. El mejor valor de *error rate* registrado durante el entrenamiento es de 0.0769, lo que significa que en la mejor época solo 2 de los 26 índices esperados (los dos contextos más frecuentes asignados a cada una de las 13 palabras del vocabulario) no coinciden con los dos índices de mayor probabilidad predichos por el circuito. Tras cargar los mejores pesos y reevaluar el circuito en inferencia con 2048 *shots*, la métrica equivalente reportada es la **top-2 accuracy**, definida como $1 - \text{error_rate}$ aplicada a la salida final del modelo, y alcanza un valor de 0.9231. Este resultado coincide con el complementario del *error rate* obtenido durante el entrenamiento, confirmando que la varianza estadística del simulador no altera el orden de los picos de probabilidad entre la evaluación durante el entrenamiento y la evaluación final.

Transición hacia el sobreentrenamiento: A partir de la iteración 360 (que coincide con el mejor resultado encontrado), se aprecia un cambio

de tendencia en la evolución tanto de la pérdida como del *error rate*. La curva pasa de un comportamiento decreciente a uno creciente, lo que indica que el modelo ha alcanzado el límite de su capacidad de generalización sobre el corpus utilizado y ha comenzado a sobreajustarse. El mecanismo de *Early Stopping* detecta esta situación y detiene el entrenamiento 100 iteraciones después por la configuración utilizada, evitando una degradación innecesaria del modelo y recuperando los pesos correspondientes al mejor *error rate* registrado.

Eficiencia de la convergencia. Cabe destacar que el modelo convergió en tan solo 360 iteraciones a pesar de utilizar 2500 épocas como límite. Frente al límite de 20.000 épocas empleado por el autor del trabajo de referencia [33] ha hecho falta una cantidad mucho menor de épocas para tener buenos resultados. Esta diferencia pone de manifiesto que los hiperparámetros configurados durante el ajuste han resultado especialmente eficaces, y es coherente con las propiedades teóricas de QN-SPSA, diseñado para alcanzar la convergencia en un número reducido de iteraciones.

Influencia del tensor métrico de Fubini-Study. Un resultado adicional de interés es que el modelo convergió antes de que el tensor métrico de Fubini-Study comenzara a aplicarse, tanto en los experimentos del *Grid Search* como en la ejecución final con un mayor número de iteraciones y *shots*. Esto sugiere que, para problemas de pequeña escala con pocos qubits, el componente de QNG no llega a contribuir de forma significativa al proceso de optimización. En la práctica, el comportamiento observado equivale al de un algoritmo SPSA bien ajustado, con una tasa de aprendizaje inicial y perturbación adecuada y el parámetro *blocking* activado. Es razonable esperar como se vio con anterioridad que el tensor métrico aporte un mayor beneficio en problemas de mayor complejidad, con vocabularios más extensos y por ende circuitos de mayor profundidad, donde con un mayor número de parámetros requiere una mayor complejidad para ajustar los valores.

4.3. Evaluación de los embeddings

El objetivo de esta sección es determinar en qué medida QWord2Vec ha sido capaz de aprender relaciones semánticas coherentes con el corpus y compararlas con las obtenidas por Word2Vec. En línea con el objetivo central de este trabajo, se busca evaluar si el espacio de Hilbert puede actuar como espacio latente para *embeddings* de palabras con resultados equiparables a los del espacio euclídeo clásico, entrenando cada modelo con las mejores técnicas disponibles en su paradigma respectivo.

Antes de presentar los resultados, es necesario precisar cómo cada modelo procesa la información de entrenamiento, ya que difieren en la cantidad y forma de los datos que consumen. *Word2Vec* entrena con todos los pares (palabra, contexto) posibles extraídos del corpus, lo que le proporciona una

mayor cobertura de las relaciones de co-ocurrencia. Por ejemplo, la palabra *dog* aparece con cinco contextos distintos en el corpus (*cat*, *like*, *fish*, *hate* y *animal*), generándose un par de entrenamiento por cada uno de ellos.

QWord2Vec, en cambio, representa cada palabra objetivo mediante un único vector de etiqueta de tamaño $N = 2^n$, en el que se asigna una probabilidad de $1/k$ a cada una de las k palabras de contexto más frecuentes y 0 al resto, de forma que el vector constituya una distribución de probabilidad válida. Siguiendo el trabajo de referencia [33], se utiliza $k = 2$, por lo que cada una de las dos palabras de contexto más frecuentes recibe una probabilidad de 0.5. Para la palabra *dog*, las dos palabras seleccionadas serían *cat* y *like*. Esta elección reduce la complejidad a la hora de optimizar para QN-SPSA, a la vez que plantea una condición de evaluación más exigente. Si *QWord2Vec* obtiene resultados comparables utilizando menos información de entrenamiento, ello reforzaría su viabilidad como una posible alternativa al modelo clásico.

La evaluación de los resultados obtenidos se divide en cuatro etapas: visualización de los *embeddings* en el plano mediante un gráfico de dispersión 2D, análisis de las similitudes de palabras mediante matrices de similitud coseno, cuantificación de la similitud entre ambas representaciones mediante el coeficiente de correlación de Pearson, y reporte de las métricas finales específicas de cada modelo, *cosine_delta* para *Word2Vec* y *top-2 accuracy* para *QWord2Vec*. Estas dos últimas métricas no son directamente comparables entre sí en términos numéricos, ya que cada una está diseñada para evaluar la propiedad semántica de su modelo correspondiente (uno en el espacio euclídeo y el otro en el espacio de Hilbert mediante probabilidades), pero ambas responden a la misma pregunta de si el modelo ha aprendido la estructura de similitud del corpus usado.

4.3.1. Visualización de los *embeddings*

La Figura 4.4 muestra los *embeddings* de ambos modelos proyectados en el plano. Para *Word2Vec*, cuyo tamaño de vector es de 2 dimensiones, no se requiere reducción dimensional. Para *QWord2Vec*, dado que los vectores de *embedding* tienen dimensión $2^n = 2^4 = 16$ (el 4 viene de utilizar 4 qubits de sistema), se ha aplicado Principal Component Analysis (PCA) para proyectarlos a 2 dimensiones, obteniendo una varianza del 74.8%. Esta reducción implica una pérdida de información considerable respecto a la métrica real en el espacio completo, por lo que las distancias observadas en la proyección deben interpretarse con cautela.

En los *embeddings* de *Word2Vec* se observan varias agrupaciones coherentes con los clústeres semánticos definidos como referencia. El par más fuerte de todo el vocabulario es *book-movie* con una similitud coseno de 0.998, seguido por *cat-animal* (0.962), *dog-eyes* (0.949), *i-hate* (0.930) y *apple-milk* (0.928). Estos pares reflejan correctamente las co-ocurrencias do-




Figura 4.4: Comparación de los embeddings obtenidos por Word2Vec (izquierda) y QWord2Vec tras reducción dimensional mediante PCA (derecha). Cada punto representa una palabra del vocabulario, coloreada según su clúster semántico de referencia: animal, food, culture y sentiment.

minantes del corpus y muestran que el modelo ha sido capaz de aprender, en términos generales, la estructura semántica esperada.

No obstante, también se aprecian relaciones que no se corresponden con la intuición semántica. Algunos pares del mismo clúster presentan similitudes inesperadamente bajas, como *dog–cat* (0.326) o *music–movie* (0.276), mientras que *dog–eyes* alcanza un valor muy alto (0.949) pese a que *eyes* pertenece al clúster animal por una sola co-ocurrencia textual. La causa principal es el reducido tamaño del corpus, con tan pocas frases, las palabras frecuentes con muchos contextos distintos (como *like*, *i* o *cat*) ven su vector dispersado en múltiples direcciones, dificultando que se acerquen a ningún término específico.

En los *embeddings* de *QWord2Vec*, los resultados proyectados muestran patrones también coherentes con las relaciones de co-ocurrencia del corpus, aunque organizados de forma distinta a los de Word2Vec. El par más cercano en la proyección PCA es *dog–animal*, con una distancia inferior a 0.013, consistente con el hecho de que ambas palabras comparten los mismos dos contextos más frecuentes (*cat* y *like*). La palabra *eyes* se sitúa próxima a este grupo (a unas 0.06 unidades de *dog* y *animal*), mientras que *cat* queda algo más alejada (en torno a 0.21 unidades). El par *like–hate* también aparece muy próximo (alrededor de 0.044) al compartir los mismos *top-2* contextos (*i* y *dog*), y *book–movie* muestra una distancia comparable (≈ 0.053), reflejando una agrupación parcial del clúster cultura.

4.3.2. Similitud coseno

Para complementar el análisis visual anterior y validarlo con mayor rigor, se presenta a continuación la matriz de similitud coseno entre todos los pares de palabras del vocabulario para cada modelo. A diferencia del gráfico de

dispersión, esta métrica opera directamente sobre los vectores completos sin aplicar ninguna reducción dimensional, por lo que ofrece una visión más fiel de la estructura aprendida. Los valores se encuentran en el rango $[0, 1]$, donde 1 indica máxima similitud y 0 ausencia de relación.




Figura 4.5: Matrices de similitud coseno para *Word2Vec* (izquierda) y *Q-Word2Vec* (derecha). Cada celda representa la similitud entre un par de palabras, donde el rojo indica alta similitud y el azul ausencia de relación.

Comenzando por los pares que ambos modelos coinciden en capturar con alta similitud, *book–movie* aparece como uno de los más fuertes en las dos representaciones, tal y como cabría esperar al pertenecer al mismo clúster semántico. *Word2Vec* también obtiene similitudes elevadas en *cat–animal* (0.962), *i–hate* (0.930) y *apple–milk* (0.928), todas ellas relaciones intra-clúster.

Las diferencias más notables aparecen en el clúster de cultura. *Word2Vec* captura con fuerza únicamente el par *book–movie* (0.998), mientras que las similitudes *book–music* (0.338) y *music–movie* (0.276) son sensiblemente bajas, dejando a *music* prácticamente desconectada del resto del clúster. *QWord2Vec*, en cambio, presenta una agrupación más equilibrada de las tres palabras de cultura, siendo el único modelo que refleja cierta cohesión simultánea entre *book*, *music* y *movie*.

La situación se invierte parcialmente en el clúster de sentimiento. *Word2Vec* agrupa con alta similitud los pares *i–hate* y *like–hate* (0.930 y 0.850 respectivamente), aunque el par *i–like* resulta sorprendentemente más bajo (0.596) por la dispersión de contextos de la palabra *like* en el corpus. *QWord2Vec* reproduce con claridad el par *like–hate*, pero *i* queda algo más desconectada de las otras dos. Esto es consecuencia directa sobre cómo se construyen las etiquetas en la versión cuántica. Al construir la etiqueta de *i* a partir de sus dos contextos más frecuentes, se descartan otras co-ocurrencias menores que sí pueden ser útiles para reflejar la cercanía semántica con *like* y *hate*, esto sin embargo *Word2Vec* sí que lo aprovecha.

Cabe señalar una limitación metodológica en la aplicación de la similitud

coseno a *QWord2Vec*. Las representaciones de este modelo son distribuciones de probabilidad sobre un espacio de 2^n estados, no vectores en un espacio euclídeo. La métrica teóricamente adecuada para comparar distribuciones de probabilidad es la **distancia de Hellinger** [19], que respeta la estructura geométrica del simplex de probabilidad. En la presente implementación se ha empleado la similitud coseno para ambos modelos por coherencia visual en la comparación de los mapas de calor, lo cual constituye una aproximación válida pero solo para vectores no negativos dado que el coseno sobre vectores no negativos mide proximidad en ángulos entre perfiles de distribución.

4.3.3. Correlación de Pearson y métricas finales

Para cuantificar en qué medida ambos modelos organizan el espacio de palabras de forma parecida, se ha calculado el coeficiente de correlación de Pearson entre los vectores de distancias coseno de *Word2Vec* y *QWord2Vec*. El valor obtenido es de 0.2920, lo que refleja una correlación baja entre las estructuras de similitud de ambos modelos. Esta métrica debe interpretarse como una *aproximación*, ya que para *QWord2Vec* se está utilizando la similitud coseno en lugar de su métrica nativa (la distancia de Hellinger mencionada) y, además, los *embeddings* cuánticos están definidos en un espacio de dimensión $2^4 = 16$ del que la proyección PCA solo conserva un 74.8% de la varianza. Aun así, sirve para evaluar de forma global cómo de parecida es la disposición de las palabras en ambos espacios. También es la principal magnitud comparativa del artículo de referencia [33], en el que se obtiene un valor de 0.81 sobre el mismo corpus aunque cabe recordar que en dicho artículo se buscaba que ambas representaciones fueran lo más parecidas posibles.

Complementariamente, se reportan las métricas finales específicas de cada modelo. *Word2Vec* alcanza un *cosine_delta* de 0.8927, que indica una clara separación entre clústeres semánticos en el espacio euclídeo. *QWord2Vec*, por su parte, alcanza una *top-2 accuracy* de 0.9231, lo que significa que el circuito predice correctamente 24 de los 26 índices esperados (los dos contextos más frecuentes para cada una de las 13 palabras del vocabulario). Como se ha indicado anteriormente, ambas métricas no son numéricamente comparables entre sí al estar diseñadas sobre espacios y características distintas, pero las dos confirman que cada modelo ha aprendido una representación semánticamente coherente sobre el corpus utilizado.

4.3.4. Discusión

Los resultados obtenidos permiten extraer conclusiones relevantes en relación con el objetivo central de este trabajo.

En primer lugar, la baja correlación de Pearson (0.2920) no debe interpretarse como un fallo de ninguno de los dos modelos, sino como evidencia

de que el espacio euclídeo y el espacio de Hilbert organizan la información semántica de forma diferente. *Word2Vec* ha aprendido una geometría mediante la optimización directa sobre todos los pares de co-ocurrencia en el espacio euclídeo, y *QWord2Vec* mediante la búsqueda de la distribución de probabilidad cuántica más cercana a los vectores de etiqueta en el espacio de Hilbert. Que ambas representaciones difieran en su estructura no contradice la validez semántica de ninguna de ellas.

En segundo lugar, las métricas finales específicas de cada modelo revelan que ambos han aprendido representaciones de calidad comparable sobre el corpus, aunque cada una se mida de acuerdo a sus características. *Word2Vec* alcanza un *cosine_delta* de 0.8927, indicando una clara separación entre los clústeres definidos en el espacio euclídeo, y *QWord2Vec* alcanza una *top-2 accuracy* de 0.9231, equivalente a la predicción correcta de 24 de los 26 índices esperados (los dos contextos más frecuentes para cada una de las 13 palabras del vocabulario). Este resultado es especialmente destacable por dos razones. Por un lado, *QWord2Vec* ha sido entrenado con menos información, ya que utiliza únicamente los dos contextos más frecuentes por palabra en lugar de todos los pares (palabra, contexto) el cual aprovecha *Word2Vec*. Por último, ninguno de los dos modelos optimiza directamente la métrica final utilizada. El *cosine_delta* guía la selección del mejor *checkpoint* en *Word2Vec* sin formar parte de su función de pérdida, y la *top-2 accuracy* se calcula a partir de la salida del circuito sin que intervenga en la función de pérdida que minimiza QN-SPSA. Que ambos modelos alcancen valores elevados en sus respectivas métricas constituye, por tanto, una evidencia indirecta pero consistente de que han aprendido la estructura semántica subyacente al corpus.

En cuanto a las limitaciones que condicionan estos resultados, cabe señalar tres factores principales. El primero es el tamaño y desequilibrio del corpus, con apenas 13 frases y un vocabulario de 13 palabras con una distribución de frecuencias muy desigual, las representaciones aprendidas por ambos modelos reflejan solo los patrones encontrados y no así una buena generalización del corpus. El segundo factor es la limitación inherente a la simulación clásica de circuitos cuánticos, que impone restricciones severas sobre el tamaño del experimento realizable (a mayor tamaño el tiempo de ejecución aumenta exponencialmente). Esto no permite acceder a las ventajas computacionales que la computación cuántica real podría ofrecer. El tercer factor es que el algoritmo utilizado *Word2Vec* lleva 13 años de mejoras desde que se publicó mientras que la versión cuántica es de hace menos de 1 año (agosto de 2025), por lo que no se tiene aún las mejores herramientas posibles para sacarle un mayor provecho a este circuito al ser una primera versión básica.

En conjunto, los resultados sugieren que, bajo las condiciones actuales y con corpus de pequeña escala, *QWord2Vec* es capaz de aprender representaciones semánticamente coherentes, comparables en calidad a las de

Word2Vec, utilizando una cantidad de información de entrenamiento menor. Esto constituye un indicador prometedor sobre la viabilidad del espacio de Hilbert como espacio latente para *word embeddings*. Para validarlo correctamente, serán necesarios experimentos con corpus más amplios y hardware cuántico real para extraer conclusiones definitivas sobre el potencial de este enfoque.

4.4. Experimentación con corpus ampliado

Una vez analizados los resultados obtenidos sobre el corpus inicial, se ha llevado a cabo una segunda fase de experimentación con el objetivo de evaluar principalmente en qué medida las limitaciones observadas son atribuibles al tamaño y al desequilibrio del corpus original. Esta segunda fase replica el procedimiento descrito sobre el primer corpus. El factor de diferencia es que ahora se utiliza un corpus ampliado, esto conlleva a realizar un reajuste de los hiperparámetros que requieren un nuevo equilibrio dada la modificación de las instancias de entrenamiento. Para evitar redundancias, esta sección describe únicamente los aspectos que cambian respecto a la primera versión del corpus utilizado, asumiendo el resto de la metodología, las métricas de evaluación y los criterios de parada ya definidos.

4.4.1. Ampliación del corpus

El nuevo corpus extiende el original hasta alcanzar las **64 frases**, manteniendo el mismo vocabulario de 13 palabras distintas. Las frases se han redistribuido de modo que cada uno de los cuatro clústeres definidos en la sección de entrenamiento (*animal*, *food*, *culture* y *sentiment*) reciba aproximadamente 16 frases, dando lugar a un corpus equilibrado en el que ningún clúster domina sobre los demás, evitando así el desbalanceo documentado del primer corpus utilizado.

Este equilibrio resulta beneficioso para ambos modelos. En *Word2Vec* evita que los pares de co-ocurrencia procedentes del clúster más numeroso dominen sobre el resto. En *QWord2Vec*, donde los vectores de etiqueta se construyen a partir de los dos contextos más frecuentes de cada palabra, una distribución de frases más uniforme genera etiquetas más representativas del vocabulario completo y reduce los sesgos hacia palabras con mayor frecuencia que el resto.

4.4.2. Reajuste de hiperparámetros

Debido al cambio en la cantidad y diversidad de las instancias de entrenamiento, se reevaluó los hiperparámetros de ambos modelos. En consecuencia, se ha repetido el procedimiento de *Grid Search* descrito previamente, man-

teniendo los mismos rangos generales y aplicando ajustes locales en torno a los valores que resultaron óptimos en la fase inicial.

En el caso de **Word2Vec**, la nueva configuración óptima es:

- *vector_size* = 4 (frente a 2 en la fase inicial).
- *window* = 2 (sin cambios).
- *alpha* = 0.068 (frente a 0.59).
- *negative* = 2 (sin cambios).
- *ns_exponent* = 0.4 (frente a 0.0).
- *epochs* = 400 (frente a 500).

El cambio más significativo es la reducción drástica de la tasa de aprendizaje inicial. En la fase anterior, el reducido tamaño del corpus exigía pasos de gradiente agresivos para escapar de mínimos locales y aprovechar al máximo cada época. Con 64 frases y al tener poca diversidad de palabras (solo 13), el modelo recibe una señal mucho más rica por época y converge con un *alpha* considerablemente más suave, lo que se traduce en una optimización más estable y menos errática. El aumento de *vector_size* de 2 a 4 es debido a que con mayor número de instancias de entrenamiento se requiere aprender un mayor número de características para diferenciar correctamente. Es decir, con 13 frases una dimensionalidad mayor habría provocado sobreajuste, mientras que con 64 frases existe señal suficiente para separar las palabras en el espacio de cuatro dimensiones de forma significativa y precisa. Para preservar la posibilidad de visualizar los *embeddings* en el plano se aplica posteriormente PCA sobre las cuatro dimensiones, conservando una varianza en torno al 86,2 %. Por último, el cambio en *ns_exponent* de 0.0 a 0.4 refleja que, al equilibrarse el corpus, ya no resulta necesario forzar una distribución uniforme de muestras negativas para compensar el desequilibrio léxico, siendo más adecuado un valor intermedio que conserve cierta proporcionalidad con la frecuencia real de cada palabra.

En el caso de **QWord2Vec**, el *Grid Search* se aplicó sobre el mismo espacio de hiperparámetros que en la fase inicial, pero el único valor que resultó modificado fue el parámetro *C* de la función de pérdida, que pondera la contribución del coeficiente de correlación de Pearson frente a la entropía cruzada. La búsqueda exploró los valores $C \in \{1, 2, 3, 4\}$, seleccionándose finalmente $C = 3$ frente al $C = 2$ utilizado en la fase inicial. Un valor mayor de *C* penaliza con más fuerza la falta de correlación entre la distribución de las palabras en el espacio de Hilbert y las etiquetas de entrenamiento establecidas. Con un corpus más amplio y rico en co-ocurrencias, la señal de correlación es más fiable y soporta mejor penalización adicional sin desestabilizar el entrenamiento pero a la vez consiguiendo una mejor representación

de los embeddings en el espacio de Hilbert. El resto de hiperparámetros del optimizador QN-SPSA se mantiene sin cambios respecto a la fase inicial, ya que la búsqueda no encontró configuraciones mejores al variarlos.

4.4.3. Resultados de Word2Vec

La Figura 4.6 muestra la evolución del entrenamiento de *Word2Vec* sobre el corpus ampliado. La curva de *cosine_delta* presenta una tendencia ascendente claramente más estable que en la fase inicial, alcanzando el mejor punto en la época época 341 exactamente con un valor de 0.9360. La pérdida de *Negative Sampling* mantiene cierto grado de oscilación, comportamiento esperable dada su naturaleza estocástica así como el problema de condición de carrera del que carece explicado con anterioridad.




Figura 4.6: Evolución del *cosine_delta* (eje izquierdo) y de la pérdida de *Negative Sampling* (eje derecho) durante el entrenamiento de *Word2Vec* sobre el corpus ampliado.

El valor final de *cosine_delta* mejora en +0.0433 puntos respecto a la fase inicial (0.9360 frente a 0.8927), confirmando que el aumento del corpus se traduce en una mejor agrupación semántica del vocabulario. La Figura 4.7 representa los *embeddings* resultantes reducido a dos dimensiones mediante la técnica de PCA.

Como se aprecia en la Figura 4.10 a pesar de haber aplicado el PCA per-




Figura 4.7: Visualización de los embeddings de Word2Vec obtenidos con el corpus ampliado, proyectados sobre las dos primeras dimensiones del espacio de embedding. Cada palabra se colorea según su clúster semántico de referencia.

diendo información importante, están bien representados los cuatro clusters definidos mediante la similitud coseno (*animal*, *food*, *culture* y *sentiment*). Con esto se aprecia que a pesar de haber habido un pequeño incremento en el *cosine_delta* final, visualmente ha habido una mejora clara en cuanto a la separación de los embeddings entre los clusters.

El análisis de las similitudes coseno por pares dentro de cada clúster, mostrado en la Figura 4.8, revela una mejora notable en la cohesión interna de la mayoría de los grupos. La diferencia más relevante respecto al corpus inicial es que se ha acentuado el contraste entre las dos regiones de la matriz, las celdas asociadas a pares disimilares se han desplazado hacia valores aún más bajos, mientras que las celdas correspondientes a pares del mismo clúster han ganado en intensidad. Es decir, al disponer de un mayor número de instancias de entrenamiento, el modelo ha sido capaz simultáneamente de discriminar mejor entre clústeres distintos y de reforzar la cohesión interna de cada uno de ellos. Esta tendencia se refleja con claridad en los valores numéricos por clúster. En el clúster *animal*, los pares *dog-cat* y *dog-animal* aumentan su similitud desde 0.326 y 0.572 hasta 0.789 y 0.916 respectivamente. En el clúster *food*, el par *fish-milk* pasa de 0.702 a 0.953, mientras que *apple-fish* se mantiene en torno a 0.914. Por último, en el clúster *culture*, el

par *music–movie* mejora de forma drástica de 0.276 a 0.934, recuperando la cohesión que en la fase inicial se concentraba artificialmente en *book–movie*.




Figura 4.8: Matrices de similitud coseno para *Word2Vec* (izquierda) y *QWord2Vec* (derecha) entrenados con el corpus ampliado.

La excepción más llamativa es el par *book–movie*, que retrocede de 0.998 a 0.167, junto con el par *book–music*, que se mantiene en un valor también bajo de 0.248. Esta caída no responde a una diferencia significativa en las co-ocurrencias entre las tres palabras del clúster *culture* (*book*, *music* y *movie*) aparecen en el corpus ampliado un número de veces juntas muy similar entre sí, por lo que el conteo de frecuencias por sí solo no permite justificar la disparidad observada. La causa más probable se encuentra en la selección estocástica de muestras negativas que realiza *Negative Sampling*, junto con el carácter no determinista del propio optimizador, puede empujar a palabras del mismo clúster en direcciones distintas cuando se seleccionan unas como negativas de otras. La configuración finalmente aprendida concentra la cohesión interna del clúster cultura en el par *music–movie* (similitud 0.934) y desplaza a *book* hacia una dirección distinta, hipotéticamente influida por sus co-ocurrencias adicionales con palabras del clúster *sentiment* a través de frases como *i like book* o *i hate book*. Esta solución resulta globalmente óptima en términos de *cosine_delta*, aun a costa de penalizar un par concreto del mismo clúster.

4.4.4. Resultados de QWord2Vec

El entrenamiento de *QWord2Vec* sobre el corpus ampliado y con la nueva configuración alcanza un *error rate* de 0.1154 en la mejor iteración, equivalente a una *top-2 accuracy* del 88.46 %. El mejor punto se localiza en torno a la iteración 400 sobre un total de 800 (debido a la tardía parada del *Early Stopping*), a partir de la cual la optimización oscila sin mejora adicional, comportamiento habitual de QN-SPSA en espacios de alta dimensión con pocos datos. La correlación de Pearson final entre las distancias coseno de

Word2Vec y *QWord2Vec* se sitúa en 0.4940, valor inferior al 0.81 reportado por el trabajo de referencia [33] pero superior al obtenido con el primer corpus inicial y desbalanceado utilizado. La Figura 4.9 muestra la evolución conjunta de la función de pérdida y del *error rate* durante el entrenamiento.




Figura 4.9: Evolución de la función de pérdida (eje izquierdo) y del error rate (eje derecho) durante el entrenamiento de *QWord2Vec* sobre el corpus ampliado.

La Figura 4.10 muestra la proyección PCA de las distribuciones de probabilidad de los *embeddings* cuánticos junto a los de *Word2Vec*, con una varianza explicada del 72.5 %, similar a la obtenida en la fase inicial. La separación entre clústeres es claramente mejor que en la versión inicial. Los clusters de *culture* y de *food* están correctamente separados y bien representados por las palabras que los componen. Sin embargo los clusters de *animal* y *sentiment* se encuentran uno superpuesto con otro. Esto principalmente puede deberse a la reducción de dimensionalidad con la pérdida de varianza tan grande que se tiene. A pesar de ello, es una clara mejora visual respecto a la primera versión de corpus.

4.4.5. Comparación entre fases

La Tabla 4.1 sintetiza las principales métricas de *Word2Vec* en ambas fases.

La mejora es generalizada en la mayoría de los pares intra-clúster. Las únicas métricas que retroceden corresponden a casos en los que la fase inicial había generado relaciones elevadas debido al desequilibrio del corpus.

En el caso de *QWord2Vec* pueden destacarse tres observaciones. En primer lugar, el *error rate* de entrenamiento aumenta de 0.0769 a 0.1154 y, de forma coherente, la *top-2 accuracy* de inferencia desciende ligeramente de 0.9231 a 0.8846. Este pequeño retroceso refleja que el corpus ampliado introduce un mayor número de co-ocurrencias distintas que el circuito debe discriminar, haciendo la tarea de aprendizaje intrínsecamente más exigente con el mismo número de qubits y la misma capacidad expresiva del circuito.




Figura 4.10: Comparación de los embeddings de Word2Vec (izquierda) y QWord2Vec (derecha) entrenados con el corpus ampliado. Para QWord2Vec se aplica PCA sobre las distribuciones de probabilidad de dimensión $2^4 = 16$.

Métrica	Fase inicial	Corpus ampliado	Δ
<i>cosine_delta</i> final	0.8927	0.9360	+0.043
<i>dog-cat</i>	0.326	0.789	+0.463
<i>dog-animal</i>	0.572	0.916	+0.344
<i>cat-animal</i>	0.962	0.910	-0.052
<i>fish-milk</i>	0.702	0.953	+0.251
<i>music-movie</i>	0.276	0.934	+0.658
<i>book-movie</i>	0.998	0.167	-0.831

Cuadro 4.1: Comparación de las similitudes coseno intra-clúster más relevantes y del *cosine_delta* global entre las dos fases de experimentación de Word2Vec.

En segundo lugar, la separación visual entre clústeres en la proyección PCA es notablemente más nítida en la segunda fase, especialmente para los grupos *food* y *culture*, que en la fase inicial aparecían más solapados. En tercer lugar, la correlación de Pearson aumenta de 0.2920 a 0.4940, lo que indica una mejor alineación entre la geometría aprendida por el circuito cuántico y la del modelo clásico, aunque sigue siendo inferior al 0.81 reportado en el trabajo de referencia [33].

La interpretación conjunta de estos resultados es que, al ampliar el corpus, el modelo cuántico reduce la precisión en la predicción palabra a palabra a cambio de una representación globalmente más estructurada la cual a su vez está mejor alineada con la geometría del modelo clásico. El descenso de la *top-2 accuracy* resulta marginal frente a la mejora sustancial de la correlación de Pearson y de la separación visual entre clústeres, lo que indica que la información semántica se distribuye de forma más coherente en el espacio de Hilbert pese a un ligero aumento en la dificultad de discriminación local. En conjunto, la segunda fase confirma que ambos modelos escalan favorable-

mente con un corpus equilibrado, siendo *Word2Vec* el que más se beneficia en términos numéricos y *QWord2Vec* el que más mejora cualitativamente en la organización del espacio de Hilbert.

4.5. Análisis de tiempos de ejecución

Además de la calidad semántica de los *embeddings*, el coste computacional constituye un factor determinante a la hora de evaluar la viabilidad práctica de ambos modelos. Los tiempos que se comentarán a continuación se han medido desde el inicio del entrenamiento, excluyendo cualquier pre-procesamiento previo, y se han obtenido ejecutando cada algoritmo en las condiciones descritas en la sección de entorno de ejecución, minimizando la interferencia de otros procesos del sistema para que así dispongan del mayor rendimiento posible. Se realizaron varias ejecuciones para verificar la consistencia de los resultados. Los valores obtenidos son prácticamente idénticos en las dos fases de experimentación descritas, dado que el aumento del corpus de 13 a 64 frases no modifica los factores que dominan el coste de cada modelo. Por ello, los tiempos se reportan de forma conjunta para ambas fases.

Word2Vec completa el entrenamiento en aproximadamente **1 segundo** en las dos fases. Este tiempo reducido se explica por dos factores principales. Por un lado, el corpus utilizado es notablemente pequeño en comparación con los conjuntos de datos para los que este tipo de modelos fue diseñado, que habitualmente comprenden cientos de miles de palabras únicas y millones de frases. Por otro lado, *Negative Sampling* actualiza únicamente un subconjunto reducido de pesos por iteración, en lugar de recalcularlo sobre todo el vocabulario. La principal fuente de sobrecarga adicional es la evaluación periódica del *cosine_delta*, necesaria para el mecanismo de *Best Model Checkpointing*, aunque su impacto sobre el tiempo total es marginal dada la brevedad del entrenamiento y lo sencillo que es computacionalmente calcular esta métrica adicional. El paso de 13 a 64 frases multiplica el número de pares (palabra, contexto) procesados por época, pero el coste por pares es tan bajo que la diferencia resulta imperceptible a escala de segundo.

QWord2Vec, por su parte, requiere aproximadamente **50 minutos** para completar el entrenamiento, también en ambas fases. Esta diferencia de tiempo tan grande respecto a *Word2Vec* se debe a la acumulación de varios factores inherentes a la simulación clásica de circuitos cuánticos. El principal cuello de botella es la evaluación de la función de pérdida. En cada llamada se transpilan y simulan los 13 circuitos cuánticos del vocabulario con 2048 *shots* por circuito mediante *AerSimulator*. La simulación clásica de circuitos cuánticos es costosa por naturaleza, ya que el espacio de estados crece exponencialmente con el número de qubits. Es importante señalar que el coste por iteración depende del tamaño del vocabulario y no del número de frases

del corpus, por lo que la ampliación de la fase inicial a la segunda fase no incrementa el tiempo de entrenamiento.

A este coste base se añaden las múltiples evaluaciones de la función de pérdida que QN-SPSA requiere por iteración para estimar simultáneamente el gradiente y el hessiano. Con un valor de *resamplings* de 5 y un *hessian delay* de 400, cada iteración genera 10 llamadas adicionales al circuito (2 necesarias para el tensor métrico de Fubini-Study por 5 *resamplings* para calcular la media obtenida) para estimar la información geométrica del espacio de parámetros. Adicionalmente, la estrategia de inicialización basada en *educated guess* introduce 10 evaluaciones previas al inicio del entrenamiento para seleccionar el mejor punto de partida. Por último, el mecanismo de *Early Stopping*, configurado para evaluar el *error rate* cada 10 iteraciones, añade un *forward pass* completo sobre todo el vocabulario en cada comprobación lo cual contribuye también al tiempo total de ejecución.

En conjunto, la diferencia de tiempos entre ambos modelos no se debe a una mayor complejidad algorítmica intrínseca de *QWord2Vec*, sino a las limitaciones actuales de los simuladores clásicos para circuitos cuánticos. *Word2Vec* opera directamente sobre matrices pequeñas ejecutadas en CPU (no requiere de tanto tiempo de computación) mediante gradiente estocástico, sin ninguna capa de simulación intermedia, lo que lo hace varias órdenes de magnitud más eficiente en el hardware disponible. Quizás si se ejecutara esto mismo en un entorno de computación cuántica real (como por ejemplo un dispositivo NISQ), podría reducirse el tiempo de entrenamiento considerablemente.

Capítulo 5

Conclusiones y trabajo futuro

5.1. Conclusiones

Este Trabajo de Fin de Grado se ha planteado con un objetivo doble como se indicó en la introducción, implementar y evaluar empíricamente el modelo cuántico QWord2Vec frente a su contraparte clásica Word2Vec, y, sobre esa base, responder a una pregunta más amplia: si el espacio de Hilbert puede actuar como espacio latente para los *embeddings* de palabras con resultados equiparables a los del espacio euclídeo clásico. La aproximación seguida se separa de la del trabajo de referencia [33] en un punto esencial. Mientras dicho estudio entrenaba ambos modelos bajo condiciones idénticas para medir hasta qué punto la versión cuántica reproducía las representaciones de la clásica, aquí se ha optado por aplicar a cada modelo las mejores técnicas disponibles dentro de su propio paradigma, con el fin de evaluar qué puede ofrecer cada uno cuando se le permite operar en su mejor versión.

Sobre esta premisa metodológica se han cumplido los objetivos formulados en el Capítulo 1.

El primer hallazgo relevante atañe a la calidad semántica de las representaciones aprendidas. Word2Vec ha obtenido un *cosine_delta* de 0.8927 en la fase inicial y de 0.9360 en la fase ampliada, evidenciando una clara separación entre los clústeres semánticos definidos sobre el corpus. QWord2Vec, por su parte, ha alcanzado una *top-2 accuracy* de 0.9231 y 0.8846 en las dos fases respectivamente, equivalentes a predecir correctamente 24 y 23 de los 26 contextos esperados. Aunque ambas métricas no sean numéricamente comparables al estar diseñadas sobre espacios distintos (euclídeo frente a Hilbert), las dos confirman que cada modelo ha aprendido una representación coherente con la estructura semántica del corpus. Este resultado adquiere mayor peso al considerar que QWord2Vec tiene una cantidad de información menor, esto es porque como se explicó Word2Vec aprende a partir de

todos los pares (palabra, contexto) extraídos del corpus, mientras que el modelo cuántico se entrena únicamente con los dos contextos más frecuentes de cada palabra objetivo, codificados en un vector de etiquetas de tamaño 2^n . Que con menos información el modelo cuántico alcance métricas comparables constituye un indicador prometedor de la viabilidad del espacio de Hilbert como espacio latente para representaciones lingüísticas, en línea con la pregunta central de este trabajo.

A esta ventaja se le suma una segunda ventaja, la cual se ve proyectada principalmente al escalar el problema. Word2Vec almacena las representaciones en dos matrices de tamaño $V \times d$ (con V el tamaño del vocabulario y d la dimensión del *embedding*), de modo que el coste en parámetros crece de forma lineal con el número de palabras. QWord2Vec, en cambio, codifica cada palabra como un estado cuántico sobre n qubits que admite hasta 2^n estados distintos en superposición, y los parámetros entrenables del circuito escalan como $\mathcal{O}(L \cdot n)$, es decir, de forma logarítmica en el tamaño del vocabulario. En el corpus utilizado en este trabajo, con apenas 13 palabras, esta ventaja no llega a materializarse, la diferencia absoluta de parámetros es pequeña y queda oculta por el coste de la simulación clásica. Sin embargo, a medida que crece V , la representación cuántica requeriría progresivamente menos memoria que la clásica para almacenar y manipular los *embeddings*, propiedad que constituye uno de los argumentos teóricos más sólidos a favor del paradigma cuántico para tareas de PLN a gran escala.

La correlación de Pearson entre los vectores de distancias coseno de ambos modelos completa esta lectura, pasando de 0.2920 en la fase inicial a 0.4940 con el corpus equilibrado. Ambos valores quedan por debajo del 0.81 reportado en el trabajo de referencia, pero esa distancia no debe interpretarse como un retroceso, sino como una consecuencia directa del objetivo planteado. El estudio original buscaba precisamente que las dos representaciones fueran lo más parecida posible, mientras que aquí cada modelo se ha entrenado para optimizar lo mejor posible su propio espacio. Es por esto que las geometrías resultantes en el espacio euclídeo y en el de Hilbert no tienen por qué coincidir. La mejora observada entre fases sugiere, además, que un corpus más rico y equilibrado favorece de forma natural una mayor alineación entre ambas representaciones.

Junto a la calidad de los *embeddings*, los resultados obtenidos confirman las propiedades teóricas atribuidas al optimizador QN-SPSA. El modelo cuántico ha convergido en aproximadamente 360 iteraciones, frente a las hasta 20 000 empleadas en el trabajo de referencia, gracias a la combinación de un ajuste fino de los hiperparámetros mediante *Grid Search* en dos fases, una inicialización por *educated guess* sobre diez candidatos aleatorios y la activación del parámetro *blocking*. Junto a esta convergencia acelerada se ha observado que el componente de QNG, no contribuye de forma significativa cuando el problema es de pequeña escala. El modelo converge antes incluso de que dicho tensor comience a aplicarse, comportándose en la práctica

como un SPSA bien ajustado. Cabe esperar que su aporte sea mayor en problemas con vocabularios extensos y circuitos más profundos.

Estos resultados deben situarse, no obstante, dentro de las limitaciones que los condicionan. La más determinante es la simulación clásica de los circuitos cuánticos, cuyo coste crece exponencialmente con el número de qubits e impone un techo práctico al tamaño del corpus manejable en un equipo personal. Su impacto se traduce de forma directa en los tiempos de ejecución medidos, aproximadamente 1 segundo para Word2Vec frente a unos 50 minutos para QWord2Vec, una diferencia de cuatro órdenes de magnitud que no responde a la complejidad algorítmica del modelo, sino al carácter clásico del simulador. Por último, conviene recordar la diferencia de madurez entre ambos paradigmas, Word2Vec lleva más de una década consolidándose como referencia del PLN, mientras que QWord2Vec se publicó hace menos de un año, por lo que el cuerpo de optimizaciones, librerías especializadas y conocimiento práctico disponibles para el modelo cuántico es todavía muy limitado.

Considerando los resultados y las limitaciones de manera conjunta, QWord2Vec demuestra ser capaz de aprender representaciones semánticamente coherentes y de calidad comparable a las de Word2Vec en corpus de pequeña escala, incluso utilizando una menor cantidad de información de entrenamiento, pero no alcanza todavía el nivel de eficiencia computacional ni de escalabilidad práctica del modelo clásico. Antes que una valoración definitiva sobre el potencial de la computación cuántica en PLN, este Trabajo de Fin de Grado debe entenderse como un análisis del estado actual del campo, una tecnología con fundamentos teóricos sólidos y resultados iniciales que se tiene esperanza pero que requiere todavía avances importantes, tanto en hardware como en algoritmia, para competir con los estándares clásicos en condiciones realistas.

5.2. Trabajo a futuro

Las conclusiones obtenidas dejan abiertas diversas líneas de investigación que prolongan de forma natural lo realizado en este trabajo. Estas líneas pueden agruparse en cuatro grandes ejes: la escalabilidad del modelo, la mejora de las métricas de evaluación, la aplicación de los *embeddings* a tareas posteriores y la exploración de variantes algorítmicas y arquitectónicas.

El primer eje, y probablemente el más urgente y evidente, es la validación de QWord2Vec sobre corpus de mayor escala. Los experimentos descritos se han limitado a vocabularios de 13 palabras debido al coste exponencial de la simulación clásica de circuitos cuánticos y que no se tiene la capacidad de cómputo local para escalar más el problema. Es decir, para superar esta barrera será necesario recurrir a simuladores desplegados en equipos de computación de alto rendimiento, en concreto a hardware cuántico real, par-

ticularmente a dispositivos NISQ. Esta validación permitiría además observar si las ventajas teóricas que se conocen del espacio de Hilbert se traducen efectivamente en mejoras prácticas cuando el problema crece, comparándolo con los resultados obtenidos en simulación.

El segundo eje afecta a la forma en que se evalúan las representaciones cuánticas. En este trabajo se ha empleado la similitud coseno por coherencia visual con la evaluación del modelo clásico, asumiendo de forma consciente que los *embeddings* de QWord2Vec son distribuciones de probabilidad y no vectores en un espacio euclídeo (aunque se haya tratado de dicha manera). La métrica teóricamente adecuada en este contexto es la distancia de Hellinger [19], que respeta la geometría natural del espacio de probabilidad y podría ofrecer una imagen más fiel de la calidad de las representaciones aprendidas. Su adopción como métrica nativa de QWord2Vec, tanto en la evaluación final como en la propia función de pérdida, constituye una línea de mejora para tener una mejor imagen y más precisa de los *embeddings* cuánticos.

El tercer eje, tal y como se señala en el artículo de referencia seguido [33], es la aplicación de los *embeddings* cuánticos a tareas posteriores. La calidad de una representación vectorial no se mide únicamente por sus propiedades intrínsecas como se ha realizado en este TFG, sino que se lleva más allá midiéndolo sobre todo por su utilidad en tareas como clasificación de texto, agrupamiento, detección de similitud o recuperación de información. Resulta particularmente atractivo el desarrollo de modelos generativos cuánticos que aprovechen estas representaciones como entrada. Esta integración con tareas reales permitiría además identificar qué propiedades del espacio de Hilbert resultan verdaderamente diferenciales en escenarios aplicados.

El cuarto eje agrupa las mejoras posibles sobre el optimizador y la arquitectura del circuito. En primer lugar, convendría comprobar si el tensor métrico de Fubini-Study aporta valor en problemas de mayor complejidad, donde el coste de su estimación se diluye frente al beneficio geométrico que introduce. En segundo lugar, existe una técnica de medición parcial sobre qubits [21], también mencionada en el artículo de referencia [33], esto permitiría aumentar la no linealidad del modelo y reducir la probabilidad de error, mejorando potencialmente la calidad de los *embeddings* sin necesidad de incrementar el número de qubits del sistema. Por último, la exploración de arquitecturas alternativas del circuito parametrizado, variando la profundidad, la disposición de las puertas de rotación o la estrategia de entrelazamiento, con el objetivo de encontrar configuraciones que ofrezcan un mejor resultado de expresividad y entrenabilidad.

Estas líneas descritas dibujan una hoja de ruta coherente para QWord2Vec, el primer circuito cuántico propuesto específicamente para este problema, con el fin de que pueda dar el salto desde su validación inicial sobre corpus reducidos y muy controlados hasta una aplicación realista en PLN. Su consecución dependerá por igual de los avances que se produzcan en el hardware cuántico y del desarrollo de nuevas técnicas algorítmicas adaptadas a

este tipo de modelos, dos frentes que decidirán hasta qué punto las ventajas teóricas del paradigma cuántico se traducen en una mejora tangible. Es precisamente esa confirmación práctica la cual es difícil de demostrar por las capacidades físicas que se tiene, la que permitirá determinar si el enfoque teórico cuántico puede tener una aplicación real.

Bibliografía

- [1] Amira Abbas y col. “The power of quantum neural networks”. En: *Nature Computational Science* 1.6 (2021), págs. 403-409. DOI: 10.1038/s43588-021-00084-1.
- [2] Zafar Ali. *A simple Word2vec tutorial*. Medium. 6 de ene. de 2019. URL: <https://medium.com/@zafaralibagh6/a-simple-word2vec-tutorial-61e64e38a6a1> (visitado 13-05-2026).
- [3] Felipe Almeida y Geraldo Xexéo. “Word Embeddings: A Survey”. En: *arXiv preprint* (2023). arXiv: 1901.09069 [cs.CL]. URL: <https://arxiv.org/abs/1901.09069>.
- [4] alreadytaikeune. *Fix computation of Word2Vec loss & add loss value to logging string*. Gensim (GitHub Pull Request #2135). 19 de jul. de 2018. URL: <https://github.com/piskvorky/gensim/pull/2135> (visitado 07-05-2026).
- [5] Frank Arute y col. “Quantum supremacy using a programmable superconducting processor”. En: *Nature* 574 (2019), págs. 505-510.
- [6] Marcello Benedetti y col. “Parameterized quantum circuits as machine learning models”. En: *Quantum Science and Technology* 4.4 (2019), pág. 043001. DOI: 10.1088/2058-9565/ab4eb5.
- [7] Jacob Biamonte y col. “Quantum machine learning”. En: *Nature* 549.7671 (2017), págs. 195-202. DOI: 10.1038/nature23474.
- [8] Matthias C Caro y col. “Generalization in quantum machine learning from few training data”. En: *Nature communications* 13.1 (2022), pág. 4919. DOI: 10.1038/s41467-022-32550-3.
- [9] Hugo Caselles-Dupré, Florian Lesaint y Jimena Royo-Letelier. “Word2Vec applied to Recommendation: Hyperparameters Matter”. En: *CoRR* abs/1804.04212 (2018). arXiv: 1804.04212. URL: <http://arxiv.org/abs/1804.04212>.

- [10] David Castaño Bandera. *4.2. El estado de un qubit y la esfera de Bloch*. Universidad de Málaga (SCBI). 28 de mayo de 2025. URL: https://www.scbi.uma.es/web/wp-content/uploads/Jupyterbook/CICC_UMA/Teoria/html/docs/Part_03/Chapter_004_02/Section_002_el_estado_de_un_qubit_y_la_esfera_de_bloch_myst.html (visitado 16-02-2026).
- [11] Yiheng Duan. *Quantum natural SPSS optimizer*. PennyLane – Xanadu. 17 de jul. de 2022. URL: <https://pennylane.ai/qml/demos/qnspss> (visitado 29-03-2026).
- [12] El Español. *¿Cuántas palabras tiene el español?* El Español. 2021. URL: https://www.elespanol.com/curiosidades/lenguaje/cuantas-palabras-tiene-espanol-castellano/641935856_0.html (visitado 25-02-2026).
- [13] Ferroviál. *¿Qué son los números complejos?* Ferroviál. 2026. URL: <https://www.ferrovial.com/es/stem/numeros-complejos/> (visitado 16-02-2026).
- [14] Julien Gacon y col. “Simultaneous Perturbation Stochastic Approximation of the Quantum Fisher Information”. En: *Quantum* 5 (20 de oct. de 2021), pág. 567. DOI: 10.22331/q-2021-10-20-567. URL: <https://quantum-journal.org/papers/q-2021-10-20-567/>.
- [15] GeeksforGeeks. *Phases of Natural Language Processing (NLP)*. GeeksforGeeks. 23 de jul. de 2025. URL: <https://www.geeksforgeeks.org/machine-learning/phases-of-natural-language-processing-nlp/> (visitado 16-02-2026).
- [16] Google. *word2vec*. Google Code Archive. 2013. URL: <https://code.google.com/archive/p/word2vec/> (visitado 26-02-2026).
- [17] Gopalan College of Engineering and Management. *Module 3: Quantum Computing & Quantum Gates*. Material de estudio. Applied Physics for Computer Science Engineering Stream. Gopalan College of Engineering y Management, 2022. URL: <https://www.gopalancolleges.com/gcem/pdf/syllabus/physics/cse/module-3-quantum-computing-quantum-gates.pdf> (visitado 16-02-2026).
- [18] Raffaele Guarasci, Giuseppe De Pietro y Massimo Esposito. “Quantum Natural Language Processing: Challenges and Opportunities”. En: *Applied Sciences* 12.11 (2022), pág. 5651. DOI: 10.3390/app12115651. URL: <https://www.mdpi.com/2076-3417/12/11/5651>.
- [19] *Hellinger Distance*. OECD.AI. URL: <https://oecd.ai/en/catalogue/metrics/hellinger-distance> (visitado 06-05-2026).

- [20] Kevin Henner. *An intuitive introduction to text embeddings*. Stack Overflow. 9 de nov. de 2023. URL: <https://stackoverflow.blog/2023/11/09/an-intuitive-introduction-to-text-embeddings/> (visitado 23-02-2026).
- [21] Hsin-Yuan Huang y col. “Power of data in quantum machine learning”. En: *Nature communications* 12.1 (2021), pág. 2631. DOI: 10.1038/s41467-021-22539-9.
- [22] IONOS. *Qubits: la base de los ordenadores cuánticos*. IONOS Digital Guide. 22 de feb. de 2023. URL: <https://www.ionos.es/digitalguide/paginas-web/desarrollo-web/qubits/> (visitado 16-02-2026).
- [23] Akbar Karimi. *NLP’s word2vec: Negative Sampling Explained*. Baeldung Computer Science. 26 de mar. de 2025. URL: <https://www.baeldung.com/cs/nlps-word2vec-negative-sampling> (visitado 03-03-2026).
- [24] levikul09. *Cosine similarity visualization*. X (formerly Twitter). URL: <https://x.com/levikul09> (visitado 13-05-2026).
- [25] Qiuchi Li y col. “Quantum-inspired complex word embedding”. En: *Proceedings of the Third Workshop on Representation Learning for NLP*. Association for Computational Linguistics, 2018, págs. 50-57. DOI: 10.18653/v1/W18-3006.
- [26] Inna Logunova y Olga Bolgurtseva. *Word2Vec: Why Do We Need Word Representations?* Serokell. URL: <https://serokell.io/blog/word2vec> (visitado 26-02-2026).
- [27] Navaneeth Malingan. *Word Embeddings with TensorFlow*. Scaler. 8 de dic. de 2023. URL: <https://www.scaler.com/topics/tensorflow/tensorflow-word-embeddings/> (visitado 13-05-2026).
- [28] Chris McCormick. *Word2Vec Tutorial - The Skip-Gram Model*. McCormick ML. 19 de abr. de 2016. URL: <https://mccormickml.com/2016/04/19/word2vec-tutorial-the-skip-gram-model/> (visitado 26-02-2026).
- [29] Chris McCormick. *Word2Vec Tutorial Part 2 - Negative Sampling*. McCormick ML. 11 de ene. de 2017. URL: <https://mccormickml.com/2017/01/11/word2vec-tutorial-part-2-negative-sampling/> (visitado 26-02-2026).
- [30] McKinsey & Company. *Quantum technology sees record investments, progress on talent gap*. McKinsey & Company. 2023. URL: <https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/quantum-technology-sees-record-investments-progress-on-talent-gap> (visitado 03-05-2026).

- [31] Tomas Mikolov y col. “Distributed Representations of Words and Phrases and their Compositionality”. En: *arXiv preprint* (2013). arXiv: 1310.4546 [cs.CL]. URL: <https://arxiv.org/abs/1310.4546>.
- [32] neptune.ai. *Word Embeddings Guide*. neptune.ai. URL: <https://neptune.ai/blog/word-embeddings-guide> (visitado 13-05-2026).
- [33] Hiroshi Ohno. “Quantum circuits for word embeddings”. En: *Quantum Machine Intelligence* (2025). DOI: 10.1007/s42484-025-00309-w. URL: <https://doi.org/10.1007/s42484-025-00309-w>.
- [34] Jeffrey Pennington, Richard Socher y Christopher D. Manning. *Glove: Global Vectors for Word Representation*. Stanford Natural Language Processing Group. URL: <https://nlp.stanford.edu/projects/glove/> (visitado 03-05-2026).
- [35] PennyLane. *Variational circuits — PennyLane*. PennyLane. URL: https://pennylane.ai/qml/glossary/variational_circuit (visitado 21-02-2026).
- [36] Rod Pierce. *Bra-Ket Notation*. MathsIsFun. 2025. URL: <https://www.mathsisfun.com/physics/bra-ket-notation.html> (visitado 16-02-2026).
- [37] Rod Pierce. *Fórmula de Euler para Números Complejos*. Disfruta Las Matemáticas. 2024. URL: <https://www.disfrutalasmatematicas.com/algebra/formula-euler.html> (visitado 16-02-2026).
- [38] Spencer Porter. *Understanding Cosine Similarity and Word Embeddings*. Medium. 28 de ago. de 2023. URL: <https://spencerporter2.medium.com/understanding-cosine-similarity-and-word-embeddings-dbf19362a3c> (visitado 25-02-2026).
- [39] Quandela. *Hilbert Space — Quantum Computing Explained*. Quandela. URL: <https://www.quandela.com/resources/quantum-computing-glossary/hilbert-space/> (visitado 03-05-2026).
- [40] Sangaku S.L. *Representación de números complejos en el plano*. Sangaku Maths. 2026. URL: <https://www.sangakoo.com/es/temas/representacion-de-numeros-complejos-en-el-plano> (visitado 16-02-2026).
- [41] Josh Schneider y Ian Smalley. *What Is Quantum Computing?* IBM. URL: <https://www.ibm.com/think/topics/quantum-computing> (visitado 03-05-2026).
- [42] Freya Shah. *Quantum Encoding: An Overview*. Quantum Zeitgeist. 2021. URL: <https://quantumzeitgeist.com/quantum-encoding-an-overview/> (visitado 18-02-2026).

- [43] Sam Sholtis. *Here's a better way to measure atomic qubits*. Futurity. 26 de mar. de 2019. URL: <https://www.futurity.org/quantum-computing-2018412/> (visitado 16-02-2026).
- [44] Peter W. Shor. "Algorithms for quantum computation: discrete logarithms and factoring". En: *Proceedings 35th Annual Symposium on Foundations of Computer Science*. 1994, págs. 124-134. DOI: 10.1109/SFCS.1994.365700.
- [45] Sukin Sim, Peter D Johnson y Alán Aspuru-Guzik. "Expressibility and entangling capability of parameterized quantum circuits for hybrid quantum-classical algorithms". En: *Advanced Quantum Technologies* 2.12 (2019), pág. 1900070.
- [46] J. C. Spall. "Implementation of the simultaneous perturbation algorithm for stochastic optimization". En: *IEEE Transactions on Aerospace and Electronic Systems* 34.3 (jul. de 1998), págs. 817-823. DOI: 10.1109/7.705889.
- [47] SpinQ Technology. *Ultimate Guide to Quantum Gates: Everything You Need to Know*. 14 de mar. de 2025. URL: <https://www.spinquanta.com/news-detail/quantum-gates> (visitado 16-02-2026).
- [48] James Stokes y col. "Quantum Natural Gradient". En: *Quantum* 4 (2020), pág. 269. DOI: 10.22331/q-2020-05-25-269. URL: <https://quantum-journal.org/papers/q-2020-05-25-269/>.
- [49] Cole Stryker y Jim Holdsworth. *What is NLP (Natural Language Processing)?* IBM. URL: <https://www.ibm.com/think/topics/natural-language-processing> (visitado 16-02-2026).
- [50] The MITRE corpustion. *The Bloch Sphere*. Intro to Quantum Software Development. 1 de jul. de 2022. URL: <https://stem.mitre.org/quantum/quantum-concepts/bloch-sphere.html> (visitado 16-02-2026).
- [51] Sik-Ho Tsang. *Review: Distributed Representations of Words and Phrases and their Compositionality — Negative Sampling (NLP)*. Medium. URL: <https://sh-tsang.medium.com/review-distributed-representations-of-words-and-phrases-and-their-compositionality-negative-ab9ebfc3f041> (visitado 01-03-2026).
- [52] Charles M. Varmantchaonala y col. "Quantum Natural Language Processing: A Comprehensive Survey". En: *IEEE Access* 12 (2024), págs. 99578-99598. DOI: 10.1109/ACCESS.2024.3420707.
- [53] *What is Grid Search?* Dremio. URL: <https://www.dremio.com/wiki/grid-search/> (visitado 04-05-2026).

- [54] Dominic Widdows y col. “Quantum Natural Language Processing”. En: *KI - Künstliche Intelligenz* 38.4 (dic. de 2024), págs. 293-310. DOI: 10.1007/s13218-024-00861-w. URL: <https://doi.org/10.1007/s13218-024-00861-w>.
- [55] Wikipedia contributors. *Bloch sphere*. Wikipedia. 15 de abr. de 2026. URL: https://en.wikipedia.org/wiki/Bloch_sphere (visitado 13-05-2026).
- [56] Wikipedia contributors. *Simultaneous perturbation stochastic approximation*. Wikipedia. URL: https://en.wikipedia.org/wiki/Simultaneous_perturbation_stochastic_approximation (visitado 29-03-2026).
- [57] Peter Wittek y col. “Combining Word Semantics within Complex Hilbert Space for Information Retrieval”. En: *Quantum Interaction*. Vol. 8369. Lecture Notes in Computer Science. Springer, 2014, págs. 160-171. URL: <https://www.diva-portal.org/smash/get/diva2:887708/FULLTEXT01.pdf>.
- [58] Yanying Wu y Quanlong Wang. *A Categorical Compositional Distributional Modelling for the Language of Life*. 2019. arXiv: 1902.09303 [q-bio.QM]. URL: <https://arxiv.org/abs/1902.09303>.
- [59] Meng Xie y col. “Modeling quantum entanglements in quantum language models”. En: *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI’15)*. AAAI Press, 2015, págs. 1362-1368.
- [60] Peng Zhang y col. “End-to-end quantum-like language models with application to question answering”. En: *Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence (AAAI’18)*. AAAI Press, 2018.
- [61] Han-Sen Zhong y col. “Quantum computational advantage using photons”. En: *Science* 370 (2020), págs. 1460-1463.

Glosario

CBOW Continuous Bag of Words.	ML Machine Learning.
CQM Categorical Quantum Mechanics.	MNL Modelo Neuronal del Lenguaje.
CVC Circuitos Variacionales Cuánticos.	NER Named Entity Recognition.
DisCoCat Distributional Compositional Categorical.	NISQ Noisy Intermediate-Scale Quantum.
DL Deep Learning.	NLP Natural Language Processing.
DPT Dependency Parse Tree.	PCA Principal Component Analysis.
DVS Descomposición en Valores Singulares.	PLN Procesamiento del Lenguaje Natural.
GD Gradient Descent.	PLNC Procesamiento del Lenguaje Natural Cuántico.
GPT Generative Pre-trained Transformer.	POS Part-of-Speech.
IA Inteligencia Artificial.	QML Quantum Machine Learning.
LLM Large Language Model.	QN-SPSA Quantum Natural Simultaneous Perturbation Stochastic Approximation.
	QNG Quantum Natural Gradient Descent.
	Qubit Quantum Bit.
	SPSA Simultaneous Perturbation Stochastic Approximation.
	WSD Word Sense Disambiguation.